

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ
CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ
NHIÊN
KHOA TOÁN - TIN HỌC**



**BÁO CÁO
KHÓA LUẬN TỐT NGHIỆP**

**ĐỀ TÀI:
ATTENTION-BASED TOKEN MERGING
FOR ASPECT-BASED SENTIMENT
ANALYSIS**

**SINH VIÊN THỰC HIỆN:
PHÙNG DŨNG QUÂN – MSSV: 22280073
NGUYỄN HỒ TUYÊN – MSSV: 22280103**

GIẢNG VIÊN HƯỚNG DẪN:
ThS. ĐOÀN THỊ TRÂM

Mục lục

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT	5
DANH MỤC BẢNG BIỂU	7
TÓM TẮT LUẬN VĂN	8
I. GIỚI THIỆU TỔNG QUAN	10
1.1. Giới thiệu	10
1.2. Mục tiêu	13
1.3. Câu hỏi nghiên cứu	15
1.4. Đối tượng và phạm vi nghiên cứu	15
1.4.1. Đối tượng nghiên cứu	15
1.4.2. Phạm vi nghiên cứu	16
II. Cơ sở lý thuyết	17
2.1. Bài toán Phân tích cảm xúc theo khía cạnh (ABSA)	17
2.1.1. Từ phân tích cảm xúc mức văn bản đến phân tích theo khía cạnh	17
2.1.2. Các bài toán con của ABSA	18
2.2. Kiến trúc Transformer và cơ chế Attention	18
2.2.1. Tổng quan kiến trúc Transformer	18
2.3. Mô hình ngôn ngữ tiền huấn luyện: BERT và T5	20
2.4. Cơ chế Local Context Focus (LCF)	21
2.4.1. Động lực: ngữ cảnh cục bộ và ngữ cảnh toàn cục	21
2.4.2. Khoảng cách ngữ nghĩa tương đối (SRD)	22
2.4.3. LCF trong kiến trúc FAST_LCF_BERT của khóa luận	23
2.5. Token Merging (ToMe): gộp token sau encoder	24
2.5.1. Động lực	24
Thuật toán gốc: Bipartite Soft Matching	24

Cài đặt ToMeSequenceMerger: ba chiến lược gộp	25
Resize: khôi phục độ dài chuỗi	25
Kiến trúc tổng thể: FAST_LCF_BERT kết hợp Token Merging	26
Pipeline tổng thể	26
Vị trí chèn Token Merging và các lựa chọn thiết kế	27
Mở rộng đa nhiệm: FastLcfBertMultiTask	28
Huấn luyện đa nhiệm và hàm mất mát	28
Độ đo đánh giá trong ABSA	29
Đánh giá trích xuất khía cạnh (ATE)	29
Đánh giá bộ ba (Joint Triplet)	29
Các hướng tiếp cận liên quan	29
Phân loại tuần tự và mô hình sinh	29
Token Merging và hiệu năng Transformer	30
Tách câu và ngữ cảnh cục bộ	30
Tóm tắt chương	30
Phương pháp thực hiện	31
Kiến trúc tổng thể	31
Bài toán và luồng xử lý đầu-cuối	31
Giải thích từng stage	32
Hai kiến trúc tổ chức: Joint và Pipeline	33
Chi tiết kiến trúc Stage APC	33
Các phương pháp	34
Phương pháp 1: Tập trung ngữ cảnh cục bộ (LCF)	34
Phương pháp 2: Gộp token (Token Merging – ToMe)	35
Huấn luyện đa nhiệm	37
Ví dụ minh họa chi tiết các phương pháp	38
Thiết lập chung	38
Ví dụ Phương pháp 1a – LCF-CDW	38
Ví dụ Phương pháp 1b – LCF-CDM	39
Ví dụ Phương pháp 2a – ToMe Bipartite	39
Ví dụ Phương pháp 2b – ToMe Sequential Local	40
Ví dụ Phương pháp 2c – ToMe Attention-Weighted	41
Ví dụ tổ hợp: LCF-CDM + Bipartite + resize	41
Tóm tắt chương	42

IV. THỰC NGHIỆM VÀ ĐÁNH GIÁ	43
1. Môi trường thực nghiệm	43
1.1 Phần cứng và phần mềm	43
1.2 Tập dữ liệu	44
1.2 Tập dữ liệu	45
1.3 Mô hình nền (Backbone)	46
2. Cài đặt siêu tham số	47
3. Thiết kế thực nghiệm	47
4. Kết quả thực nghiệm	48
4.1 Kết quả với backbone BERT	48
4.2 Kết quả với backbone T5	49
4.3 Phân tích theo lớp cảm xúc	49
4.4 Phân tích theo lớp category	49
5. Phân tích và thảo luận	50
5.1 Hiệu quả của Token Merging trong ABSA	50
5.2 So sánh các chiến lược Token Merging	51
5.3 CDM so với CDW trong kết hợp với ToMe	52
5.4 So sánh giữa hai backbone	52
5.5 Hạn chế và hướng cải thiện	53
6. Thực nghiệm ablation	53
Tổng kết chương	54
V. Kết luận và Hướng phát triển	55
1. Tóm tắt các đóng góp chính	55
1.1 Mô-đun AToMe (Attention-based Token Merging)	55
1.2 Kiến trúc hai giai đoạn tích hợp (Two-Stage Pipeline)	56
1.3 Đánh giá toàn diện trên SemEval-2016 Task 5 REST16	56
2. Những phát hiện chính	57
2.1 Token merging giảm độ phức tạp tính toán mà vẫn duy trì hiệu suất	57
2.2 LCF tăng hiệu quả của token merging	57
2.3 Attention-weighted merging ưu tiên các token theo mức độ quan trọng	57
2.4 Cân bằng giữa các lớp ít thường xuyên	58
3. Những hạn chế của nghiên cứu hiện tại	58

3.1 Giới hạn về dữ liệu	58
3.2 Giới hạn kiến trúc	58
3.3 Giới hạn thí nghiệm	59
3.4 Giới hạn phương pháp token merging	59
4. Hướng phát triển tương lai	59
4.1 Mở rộng đến các miền dữ liệu khác	60
4.2 Tích hợp với Large Language Models (LLM)	60
4.3 Cải tiến kiến trúc token merging	60
4.4 Nghiên cứu sâu về phân tích lỗi	61
4.5 Thử nghiệm Aspect-Category-Sentiment (ASTE)	61
4.6 Tối ưu hóa tính khả dụng thực tế	61
5. Tác động và ứng dụng thực tế	62
5.1 Ứng dụng trong phân tích review sản phẩm	62
5.2 Tính hiệu quả tính toán	62
Lời kết	62
TÀI LIỆU THAM KHẢO	63
LINK CODE GITHUB	64

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Lĩnh vực NLP và Machine Learning:

- ABSA - Aspect-Based Sentiment Analysis (Phân tích cảm xúc dựa trên khía cạnh)
- NLP - Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
- LLM - Large Language Model (Mô hình ngôn ngữ lớn)
- BERT - Bidirectional Encoder Representations from Transformers
- RoBERTa - Robustly Optimized BERT Pretraining Approach
- DeBERTa - Decoding-enhanced BERT with Disentangled Attention
- DistilBERT - Distilled version of BERT
- LoRA - Low-Rank Adaptation
- QLoRA - Quantized Low-Rank Adaptation
- PEFT - Parameter-Efficient Fine-Tuning
- NSP - Next Sentence Prediction

Kỹ thuật và Định dạng:

- GGUF - GPT-Generated Unified Format
- NF4 - NormalFloat 4-bit
- FP16 - Floating Point 16-bit
- FP32 - Floating Point 32-bit
- LCS - Longest Common Subsequence
- JSON - JavaScript Object Notation
- CSV - Comma-Separated Values
- HTML - HyperText Markup Language

- CUDA - Compute Unified Device Architecture
- GPU - Graphics Processing Unit
- VRAM - Video Random Access Memory

Độ đo đánh giá:

- TP - True Positive
- FP - False Positive
- FN - False Negative

Danh sách bảng

1	Các bài toán con của ABSA	18
2	Hai kiến trúc tổ chức bài toán đầu-cuối	33
3	Ba chiến lược gộp token được khảo sát	36
4	Thiết lập ví dụ: 13 token hợp lệ với vector ẩn 4 chiều	38
5	Trọng số CDW cho các vị trí có $SRD > \alpha$	39
6	So sánh CDW và CDM tại các vị trí 10–12	39
7	Bipartite – chọn cặp và khử trùng (bước 1)	40
8	Cấu hình môi trường thực nghiệm	43
9	Danh mục các khía cạnh trong lĩnh vực khách sạn	44
10	Các nhóm phân cực cảm xúc	44
11	Thống kê tập dữ liệu En	45
12	Phân phối nhãn cảm xúc trên tập Train	45
13	Phân phối nhãn category trên tập Train	46
14	Thống kê tập dữ liệu SemEval-2016 REST16	46
15	Siêu tham số chung cho tất cả thí nghiệm	47
16	Kết quả các cấu hình trên tập test (backbone BERT)	49
17	Kết quả các cấu hình trên tập test (backbone T5-base)	50
18	F1 theo lớp cảm xúc – backbone BERT	50
19	F1 theo lớp category – backbone BERT	51
20	Ablation study – tác động từng thành phần (BERT)	53

TÓM TẮT LUẬN VĂN

Phân tích cảm xúc dựa trên khía cạnh (Aspect-Based Sentiment Analysis — ABSA) là một bài toán quan trọng trong xử lý ngôn ngữ tự nhiên, với mục tiêu phân tích không chỉ cực tính cảm xúc chung của văn bản mà còn xác định thái độ cụ thể hướng đến từng khía cạnh (aspect) được nhắc đến. Mặc dù các mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer đã đạt hiệu suất cao trong ABSA, chi phí tính toán của cơ chế self-attention tăng theo bình phương độ dài chuỗi, đặt ra thách thức về hiệu quả trong triển khai thực tế.

Luận văn này đề xuất và nghiên cứu một phương pháp kết hợp Token Merging (ToMe) với cơ chế Local Context Focus (LCF) nhằm cải thiện hiệu quả tính toán trong khi duy trì chất lượng biểu diễn ngữ nghĩa cho bài toán ABSA. Cụ thể, ba chiến lược gộp token được thiết kế và so sánh: (i) Bipartite Matching — phân chia chuỗi token thành hai nhóm xen kẽ và ghép cặp dựa trên độ tương đồng cosine (theo phương pháp ToMe gốc, CVPR 2023); (ii) Sequential Local Merging — quét tuần tự từ trái sang phải, mỗi token hợp nhất với lân cận có độ tương đồng cao hơn; (iii) Attention-Weighted Merging — ưu tiên gộp các token có trọng số attention thấp trước, bảo vệ các vị trí có giá trị ngữ nghĩa cao (bao gồm vị trí khía cạnh được đánh dấu bởi LCF). Module LCF với cơ chế CDM/CDW được tích hợp để bảo vệ ngữ cảnh cục bộ quanh aspect term khỏi quá trình gộp, đảm bảo thông tin phân tích cảm xúc không bị mất.

Mô hình được huấn luyện và đánh giá trên tập dữ liệu chuẩn SemEval 2016 Task 5 (REST16) theo kiến trúc đa nhiệm (multi-task) đồng thời giải quyết hai bài toán: Phân loại cực tính cảm xúc theo khía cạnh (Aspect Polarity Classification — APC) và Phân loại danh mục khía cạnh (Aspect Category Classification). Thực nghiệm được tiến hành với resize mode (giữ nguyên chiều dài chuỗi sau khi gộp bằng nội suy).

Kết quả thực nghiệm cho thấy các chiến lược token merging được đề xuất có thể duy trì chất lượng phân loại cạnh tranh so với mô hình nền, đồng thời giảm số

lượng token thực sự được xử lý qua các lớp tiếp theo. Nghiên cứu cũng chỉ ra rằng việc bảo vệ các vị trí đặc biệt ([CLS], [SEP]) và vị trí khía cạnh trong quá trình gộp là yếu tố then chốt để duy trì hiệu suất phân tích cảm xúc.

Luận văn đóng góp: (1) phân tích hệ thống ba chiến lược token merging trong ngữ cảnh ABSA; (2) cơ chế tích hợp LCF-aware merging bảo vệ thông tin ngữ cảnh cục bộ; (3) kiến trúc đa nhiệm kết hợp APC và phân loại danh mục trên cùng một backbone; (4) bộ thực nghiệm đầy đủ với phân tích per-class F1 theo cục tính và danh mục khía cạnh.

I. GIỚI THIỆU TỔNG QUAN

1.1. Giới thiệu

Sự phát triển mạnh mẽ của các nền tảng đặt phòng trực tuyến và mạng xã hội du lịch đã làm gia tăng đáng kể số lượng cũng như mức độ chi tiết của các đánh giá (review) do khách hàng để lại cho các cơ sở lưu trú. Một đánh giá thường đồng thời đề cập đến nhiều khía cạnh khác nhau của dịch vụ với các sắc thái cảm xúc không giống nhau. Chẳng hạn, câu “*The room was beautiful but the staff was rude*” thể hiện cảm xúc tích cực đối với khía cạnh *phòng* (FACILITY) nhưng lại mang cảm xúc tiêu cực đối với khía cạnh *nhân viên* (SERVICE). Tuy nhiên, các phương pháp phân tích cảm xúc truyền thống thường chỉ gán một nhãn cảm xúc duy nhất cho toàn bộ câu hoặc đoạn văn, do đó không phản ánh được những cảm xúc trái ngược cùng tồn tại trong một nhận xét. Điều này khiến doanh nghiệp gặp khó khăn trong việc xác định chính xác các điểm mạnh và hạn chế của dịch vụ để có những điều chỉnh phù hợp.

Để giải quyết hạn chế trên, bài toán phân tích cảm xúc theo khía cạnh (*Aspect-Based Sentiment Analysis* – ABSA) đã được đề xuất và trở thành một hướng nghiên cứu quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên. Mục tiêu của ABSA là xác định cảm xúc tương ứng với từng khía cạnh cụ thể được đề cập trong văn bản thay vì chỉ đánh giá cảm xúc ở mức toàn câu. Hai bài toán con phổ biến của ABSA bao gồm: (1) *Aspect Term Extraction* (ATE), có nhiệm vụ trích xuất các cụm từ biểu diễn khía cạnh xuất hiện trong câu; và (2) *Aspect (Category) Polarity Classification* (APC), thực hiện phân loại nhóm khía cạnh và xác định cảm xúc tương ứng (tích cực, tiêu cực hoặc trung lập) cho từng khía cạnh đó. Trong bối cảnh các mô hình ngôn ngữ tiên huấn luyện phát triển mạnh mẽ, kiến trúc Transformer, đặc biệt là BERT [2], đã mang lại những cải thiện đáng kể về hiệu quả của các hệ thống ABSA. Trên cơ sở đó, cơ chế *Local Context Focus* (LCF) được đề xuất bởi Zeng

và cộng sự [6] nhằm tăng cường khả năng tập trung vào vùng ngữ cảnh xung quanh khía cạnh đang xét. Kết hợp với các nghiên cứu khai thác BERT cho ABSA của Li và cộng sự [3], kiến trúc *FAST-LCF-BERT* đã chứng minh khả năng nâng cao độ chính xác phân loại cảm xúc nhờ tận dụng đồng thời thông tin ngữ cảnh toàn cục và thông tin cục bộ liên quan trực tiếp đến khía cạnh.

Trong đề tài này, bài toán ATE không được giải quyết theo hướng gán nhãn chuỗi truyền thống sử dụng sơ đồ BIO, mà được hình thức hóa thành bài toán sinh có điều kiện (*conditional generation*) dựa trên mô hình ngôn ngữ T5. Cụ thể, mô hình T5AspectExtractor, được xây dựng trên nền tảng T5ForConditionalGeneration với backbone t5-base, nhận đầu vào là câu đánh giá và sinh trực tiếp danh sách các cụm từ khía cạnh dưới dạng chuỗi có cấu trúc theo định dạng GAS (*Generative Aspect-based Sentiment*). Ví dụ, đầu ra của mô hình có thể là "(room); (staff); (elevator)"; trong trường hợp câu không chứa khía cạnh, mô hình sinh ra chuỗi "none". So với phương pháp gán nhãn token truyền thống, cách tiếp cận sinh này giúp loại bỏ nhu cầu thiết kế nhãn thủ công và linh hoạt hơn trong việc xử lý các câu chứa nhiều khía cạnh với số lượng không cố định. Tuy nhiên, do đặc trưng của các mô hình sinh, đầu ra có thể không khớp hoàn toàn với văn bản gốc do lỗi chính tả hoặc hiện tượng thiếu, thừa từ. Để khắc phục vấn đề này, đầu ra của T5 được hậu xử lý bằng kỹ thuật đối sánh n-gram dựa trên khoảng cách Levenshtein. Theo đó, mỗi cụm từ được sinh ra sẽ được ánh xạ tới n-gram gần nhất thực sự xuất hiện trong câu, bảo đảm rằng các khía cạnh cuối cùng luôn là các chuỗi con hợp lệ của văn bản đầu vào.

Dựa trên module ATE nói trên, đề tài khảo sát hai kiến trúc ABSA đầu-cuối nhằm trích xuất bộ ba thông tin gồm (*cụm từ khía cạnh, nhóm khía cạnh, cảm xúc*). Kiến trúc thứ nhất là kiến trúc **Joint**, trong đó hai bài toán ATE và APC được huấn luyện và đánh giá đồng thời trong cùng một quy trình. Cách tiếp cận này cho phép tận dụng mối liên hệ giữa hai nhiệm vụ, đồng thời hạn chế hiện tượng lan truyền lỗi giữa các giai đoạn xử lý. Kiến trúc thứ hai là kiến trúc **Pipeline**, trong đó mô hình T5 thực hiện trích xuất khía cạnh trước, sau đó các cụm từ khía cạnh thu được được chuyển sang module APC dựa trên FAST-LCF-BERT để phân loại nhóm khía cạnh và cảm xúc một cách độc lập. Mặc dù kiến trúc Pipeline mang lại tính linh hoạt cao do cho phép thay thế hoặc cải tiến riêng từng thành phần, kết quả thực nghiệm cho thấy độ chính xác của ATE suy giảm đáng kể so với kiến trúc Joint. Cụ thể, chỉ số F1 của ATE trong kiến trúc Pipeline chỉ đạt khoảng 60%, thấp

hơn đáng kể so với mức 79,87% của kiến trúc Joint. Kết quả này phản ánh rõ ảnh hưởng của hiện tượng lan truyền lỗi khi quá trình trích xuất khía cạnh và phân loại cảm xúc được tách rời thành hai giai đoạn độc lập.

Bên cạnh những cải thiện về độ chính xác, các mô hình dựa trên Transformer cũng đi kèm với chi phí tính toán đáng kể do cơ chế tự chú ý (*self-attention*) có độ phức tạp bậc hai theo độ dài chuỗi đầu vào, tức $O(L^2)$ với L là số lượng token. Khi độ dài chuỗi tăng lên, số lượng phép tính cần thực hiện trong các lớp attention tăng rất nhanh, kéo theo thời gian suy luận và nhu cầu tài nguyên phần cứng lớn hơn. Trong bối cảnh triển khai thực tế, chẳng hạn như các hệ thống chăm sóc khách hàng cần xử lý số lượng lớn phản hồi theo thời gian gần thực, chi phí tính toán này trở thành một thách thức đáng kể. Vấn đề càng trở nên nghiêm trọng khi mô hình được huấn luyện theo hướng đa nhiệm, đồng thời dự đoán nhóm khía cạnh và cảm xúc trên các câu dài chứa nhiều thông tin dư thừa như từ dừng, dấu câu hoặc các token mang ý nghĩa tương tự nhau.

Một hướng tiếp cận gần đây nhằm giảm chi phí suy luận của Transformer là phương pháp *Token Merging* (ToMe) [1]. Ban đầu được đề xuất cho Vision Transformer, ToMe dựa trên ý tưởng gộp các token có biểu diễn tương đồng thành một token đại diện thông qua độ tương đồng cosine giữa các vector embedding. Nhờ đó, số lượng token được giảm dần qua các lớp xử lý mà không cần huấn luyện lại mô hình từ đầu, giúp cải thiện đáng kể tốc độ suy luận. Ý tưởng này mở ra khả năng áp dụng cho các mô hình ABSA nhằm giảm chi phí tính toán trong các lớp xử lý phía sau của FAST-LCF-BERT. Tuy nhiên, việc áp dụng trực tiếp chiến lược ghép cặp hai phía (*bipartite matching*) của ToMe cho bài toán ABSA tiềm ẩn nguy cơ làm mất đi thông tin ngữ nghĩa quan trọng. Đặc biệt, các token thuộc cụm từ khía cạnh, vốn được nhấn mạnh bởi cơ chế LCF, có thể bị gộp với các token khác chỉ dựa trên độ tương đồng biểu diễn mà không xét đến vai trò của chúng trong việc xác định cảm xúc. Điều này có thể làm suy giảm chất lượng biểu diễn cục bộ và ảnh hưởng tiêu cực đến độ chính xác của mô hình.

Từ những phân tích trên có thể thấy rằng, mặc dù Token Merging đã chứng minh hiệu quả trong việc giảm chi phí tính toán của Transformer, các nghiên cứu hiện nay chủ yếu tập trung vào chiến lược ghép cặp hai phía ban đầu và chưa xem xét đầy đủ sự tương tác giữa quá trình gộp token với cơ chế *Local Context Focus* trong các mô hình ABSA đa nhiệm. Bên cạnh đó, vẫn còn thiếu các nghiên cứu đánh giá một cách hệ thống nhiều chiến lược gộp token khác nhau, chẳng

hạn như các phương pháp dựa trên quan hệ lân cận tuần tự hoặc dựa trên trọng số chú ý, trong bối cảnh đồng thời dự đoán nhóm khía cạnh và cảm xúc. Khoảng trống nghiên cứu này chính là động lực để thực hiện đề tài “*Attention-based Token Merging Aspect-Based Sentiment Analysis*”. Mục tiêu của đề tài là xây dựng và đánh giá thực nghiệm các chiến lược gộp token mới trong sự kết hợp với cơ chế LCF trên bộ dữ liệu đánh giá khách sạn thực tế, từ đó tìm kiếm sự cân bằng hợp lý giữa hiệu quả tính toán và độ chính xác của mô hình, góp phần nâng cao khả năng ứng dụng của các hệ thống ABSA trong thực tiễn.

1.2. Mục tiêu

Đề tài hướng đến các mục tiêu cụ thể sau:

1. Xây dựng hệ thống ABSA đầu-cuối (*end-to-end Aspect-Based Sentiment Analysis*) bao gồm hai bài toán con:
 - *Aspect Term Extraction* (ATE): trích xuất các cụm từ khía cạnh xuất hiện trong câu đánh giá bằng mô hình sinh có điều kiện dựa trên T5.
 - *Aspect (Category) Polarity Classification* (APC): xác định đồng thời nhóm khía cạnh và cảm xúc tương ứng với từng cụm từ khía cạnh được trích xuất.
2. Xây dựng mô hình APC đa nhiệm (*multi-task*) dựa trên kiến trúc FAST-LCF-BERT, đồng thời dự đoán:
 - cảm xúc gồm ba lớp: *positive*, *negative* và *neutral*;
 - nhóm khía cạnh gồm sáu lớp: SERVICE, FACILITY, AMENITY, EXPERIENCE, BRANDING và LOYALTY.
3. Tích hợp mô-đun *Token Merging* vào đầu ra của BERT, cho phép cấu hình bật/tắt độc lập với cơ chế *Local Context Focus* (LCF), đồng thời hỗ trợ lựa chọn giữ nguyên độ dài chuỗi sau khi gộp (*resize*) nhằm đánh giá chính xác tác động của việc giảm số lượng token đến hiệu năng tính toán và tốc độ suy luận.
4. Đề xuất và triển khai hai chiến lược gộp token mới bên cạnh chiến lược ghép cặp *bipartite matching* của ToMe:

- **Sequential Local Merging:** thực hiện so sánh độ tương đồng của mỗi token với hai token lân cận (trái/phải) theo thứ tự tuần tự và gộp dần qua từng vòng quét.
 - **Attention-weighted Merging:** ưu tiên gộp các token có trọng số chú ý thấp, đồng thời bảo vệ các token thuộc vị trí khía cạnh (được đánh dấu bởi LCF) cũng như các token có trọng số chú ý cao nhằm hạn chế mất mát thông tin ngữ nghĩa quan trọng.
5. Thiết kế và thực hiện bộ thực nghiệm có kiểm soát với 12 cấu hình khác nhau, kết hợp các yếu tố:
- Ba cấu hình của cơ chế LCF: không sử dụng LCF, sử dụng *Context Dynamic Masking* (CDM) hoặc sử dụng *Context Dynamic Weighting* (CDW);
 - Có hoặc không sử dụng Token Merging;
 - Ba chiến lược gộp token khác nhau, bao gồm *bipartite matching*, *Sequential Local Merging* và *Attention-weighted Merging*.
- Qua đó, đánh giá ảnh hưởng riêng lẻ cũng như sự tương tác giữa các yếu tố trên đối với hiệu năng của mô hình thông qua các chỉ số thời gian huấn luyện, thời gian suy luận, Macro-F1 và Micro-F1 cho cả hai đầu ra là cảm xúc và nhóm khía cạnh. Qua đó, đánh giá ảnh hưởng riêng lẻ cũng như sự tương tác giữa các yếu tố trên đối với hiệu năng của mô hình thông qua các chỉ số như thời gian huấn luyện, thời gian suy luận, Macro-F1 và Micro-F1 cho cả hai đầu ra là cảm xúc và nhóm khía cạnh.
6. Xây dựng và xử lý bộ dữ liệu ABSA tiếng Anh từ các đánh giá khách sạn thực tế, kết hợp kỹ thuật tăng cường dữ liệu (*data augmentation*) với dữ liệu SemEval Restaurant nhằm giảm thiểu vấn đề mất cân bằng lớp, đặc biệt đối với các lớp cảm xúc *negative* và *neutral* vốn chiếm tỷ lệ nhỏ trong dữ liệu gốc.
7. Xây dựng quy trình suy luận hoàn chỉnh cho hệ thống ABSA đầu-cuối. Cụ thể, các câu đánh giá dài được tách thành các mệnh đề (*clause*) tương ứng với từng khía cạnh bằng mô hình ngôn ngữ lớn Qwen3:8B, sau đó các cụm từ khía cạnh được trích xuất bằng mô hình T5 và được đưa vào mô hình

APC dựa trên FAST-LCF-BERT để thu được bộ ba thông tin (*aspect term*, *aspect category*, *sentiment*) phục vụ cho các ứng dụng phân tích phản hồi khách hàng trong thực tế.

1.3. Câu hỏi nghiên cứu

Từ khoảng trống nghiên cứu đã được trình bày, luận văn tập trung trả lời các câu hỏi nghiên cứu sau:

- **RQ1:** Việc áp dụng Token Merging vào kiến trúc FAST-LCF-BERT có giúp giảm chi phí tính toán và thời gian suy luận mà vẫn duy trì được hiệu năng của bài toán ABSA đa nhiệm hay không?
- **RQ2:** Các chiến lược gộp token khác nhau (*Bipartite Matching*, *Sequential Local Merging* và *Attention-weighted Merging*) ảnh hưởng như thế nào đến độ chính xác của mô hình trên hai nhiệm vụ dự đoán cảm xúc và nhóm khía cạnh?
- **RQ3:** Sự kết hợp giữa cơ chế Local Context Focus (CDM hoặc CDW) và Token Merging tác động như thế nào đến khả năng bảo toàn thông tin cục bộ liên quan đến khía cạnh?
- **RQ4:** Chiến lược *Attention-weighted Merging* có đạt được sự cân bằng tốt hơn giữa hiệu năng tính toán và độ chính xác so với chiến lược ToMe gốc hay không?

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm:

- Văn bản đánh giá (review) của khách hàng đối với dịch vụ khách sạn, viết bằng tiếng Anh lẫn tiếng Việt, được gán nhãn theo định dạng *aspect term*, *aspect category*, *sentiment*.

- Kiến trúc mô hình FAST-LCF-BERT và cơ chế Local Context Focus (LCF) áp dụng cho bài toán phân loại *aspect category*, *sentiment* theo *aspect term*.
- Kỹ thuật Token Merging (ToMe) và các chiến lược lựa chọn cặp token để gộp dựa trên *cosine similarity* và/hoặc *attention weight*.

1.4.2. Phạm vi nghiên cứu

Luận văn tập trung nghiên cứu bài toán phân tích cảm xúc theo khía cạnh trên miền đánh giá khách sạn bằng tiếng Anh. Trong đó:

- Bài toán ATE được xây dựng theo hướng sinh có điều kiện sử dụng mô hình T5-base.
- Bài toán APC được xây dựng trên kiến trúc FAST-LCF-BERT đa nhiệm, đồng thời dự đoán nhóm khía cạnh và cảm xúc.
- Các thực nghiệm chỉ khảo sát ba chiến lược Token Merging gồm *Bipartite Matching*, *Sequential Local Merging* và *Attention-weighted Merging*.
- Cơ chế Local Context Focus được xem xét với hai biến thể CDM và CDW.
- Bộ dữ liệu sử dụng thuộc miền khách sạn với sáu nhóm khía cạnh và ba nhãn cảm xúc.

Luận văn không xem xét các mô hình ngôn ngữ lớn có kích thước lớn hơn BERT, không khảo sát các phương pháp nén mô hình khác như pruning hoặc quantization, cũng như chưa mở rộng sang các miền dữ liệu khác ngoài lĩnh vực khách sạn.

II. Cơ sở lý thuyết

Chương này trình bày các nền tảng lý thuyết được sử dụng trực tiếp trong hệ thống cài đặt của khóa luận. Nội dung được tổ chức theo trình tự từ bài toán (Phân tích cảm xúc theo khía cạnh), đến kiến trúc nền (Transformer, BERT, T5), cơ chế tập trung ngữ cảnh cục bộ (Local Context Focus – LCF), kỹ thuật gộp token (Token Merging – ToMe), và cuối cùng là cách các thành phần này được ghép lại thành kiến trúc tổng thể FAST_LCF_BERT / FastLcfBertMultiTask đang được sử dụng làm baseline thực nghiệm. Mỗi phần lý thuyết đều được đối chiếu trực tiếp với mã nguồn tương ứng trong repo để bảo đảm tính nhất quán giữa lý thuyết và cài đặt.

2.1. Bài toán Phân tích cảm xúc theo khía cạnh (ABSA)

2.1.1. Từ phân tích cảm xúc mức văn bản đến phân tích theo khía cạnh

Phân tích cảm xúc (Sentiment Analysis) truyền thống thường được thực hiện ở mức câu hoặc mức văn bản: gán cho toàn bộ đoạn văn một nhãn cảm xúc duy nhất (tích cực / tiêu cực / trung lập). Cách tiếp cận này bộc lộ hạn chế rõ rệt khi một câu chứa nhiều đối tượng (khía cạnh) với cảm xúc khác nhau. Ví dụ câu đánh giá:

“The room was beautiful but the staff was rude.”

chứa hai khía cạnh *room* (cảm xúc **Positive**) và *staff* (cảm xúc **Negative**). Một mô hình phân loại cảm xúc mức câu sẽ không biểu diễn được sự mâu thuẫn này. **Phân tích cảm xúc theo khía cạnh** (Aspect-Based Sentiment Analysis – ABSA) ra đời để giải quyết vấn đề trên: với mỗi khía cạnh (aspect term / aspect category) xuất hiện trong câu, mô hình cần dự đoán cảm xúc tương ứng dựa trên ngữ cảnh cục bộ xung quanh khía cạnh đó.

2.1.2. Các bài toán con của ABSA

ABSA không phải một bài toán đơn lẻ mà là một nhóm các bài toán con, khác nhau ở đầu vào/đầu ra và mức độ chi tiết của thông tin cần trích xuất (Bảng 1) [4].

Bảng 1: Các bài toán con của ABSA

Bài toán	Tên đầy đủ	Đầu vào	Đầu ra
ATE	Aspect Term Extraction	Câu	Danh sách cụm từ khía cạnh
APC	Aspect (Category) Polarity Classification	Câu + khía cạnh	Nhãn cảm xúc + nhóm khía cạnh
ASTE	Aspect Sentiment Triplet Extraction	Câu	(khía cạnh, ý kiến, cảm xúc)
ASQP	Aspect-Category-Opinion-Sentiment Quad	Câu	(khía cạnh, danh mục, ý kiến, cảm xúc)

Trong phạm vi khóa luận, hai bài toán con được giải quyết trực tiếp là:

- **ATE** – trích xuất *vị trí* các cụm từ khía cạnh (ví dụ: *room, staff*); trong khóa luận, ATE được hình thức hóa thành bài toán sinh có điều kiện và giải bằng mô hình T5 (xem mục).
- **APC** – bài toán **trọng tâm của khóa luận**: cho trước khía cạnh, mô hình dự đoán đồng thời *cảm xúc* (Positive / Negative / Neutral) và *nhóm khía cạnh* (ví dụ SERVICE, FACILITY, AMENITY, EXPERIENCE, BRANDING, LOYALTY) cho khía cạnh đó, thông qua kiến trúc FAST_LCF_BERT.

Các bài toán end-to-end phức tạp hơn (ASTE, ASQP) được khảo sát để hiểu bối cảnh nghiên cứu chung của ABSA và làm cơ sở định hướng mở rộng, nhưng không nằm trong phạm vi thực nghiệm trực tiếp.

2.2. Kiến trúc Transformer và cơ chế Attention

2.2.1. Tổng quan kiến trúc Transformer

Transformer [5] là kiến trúc nền tảng của hầu hết các mô hình ngôn ngữ hiện đại, bao gồm BERT và T5 được sử dụng làm encoder trong khóa luận. Khác với

RNN/LSTM, Transformer xử lý toàn bộ chuỗi đầu vào *đồng thời*, thay thế cơ chế hồi quy bằng **self-attention**, cho phép mỗi token “nhìn” trực tiếp tới mọi token khác bất kể khoảng cách, đồng thời tận dụng tối đa khả năng tính toán song song trên GPU. Một khối encoder gồm hai thành phần chính được lặp lại nhiều lần: **Multi-Head Self-Attention (MHSA)** và **Feed-Forward Network (FFN)**, mỗi thành phần được bao bởi **kết nối tắt (residual)** và **Layer Normalization**.

Self-Attention và Multi-Head Self-Attention

Với chuỗi gồm n token, mỗi token là một vector d_{model} chiều tạo thành ma trận $X \in \mathbb{R}^{n \times d_{model}}$. Self-attention chiếu X thành Query, Key, Value:

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V \quad (1)$$

Đầu ra attention được tính bằng **tích vô hướng tỉ lệ**:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \quad (2)$$

Hệ số $\sqrt{d_k}$ tránh tích vô hướng quá lớn làm softmax bão hòa. Transformer dùng **nhiều đầu attention** song song, mỗi đầu học một loại quan hệ ngữ nghĩa/cú pháp khác nhau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (3)$$

Đây chính là thành phần được tái sử dụng trong các lớp self-attention (`bert_SA`, `bert_SA_`) của kiến trúc FAST_LCF_BERT (mục), cài đặt qua lớp `nn.MultiheadAttention` trong `_SALayer` (`models/fast_lcf_bert_multitask.py`).

Một điểm quan trọng cho Token Merging (mục) là chi phí của (2) tỉ lệ $O(n^2 \cdot d_k)$ do tích $QK^\top$ tạo ra ma trận attention kích thước $n \times n$. Khi n giảm (nhờ gộp token), chi phí của các lớp self-attention *phía sau* điểm gộp giảm theo bậc hai – đây là động lực cốt lõi của Token Merging.

Positional Encoding, Feed-Forward và chuẩn hóa

Vì self-attention không có khái niệm thứ tự, Transformer gốc bổ sung **positional encoding** dạng sin/cos vào embedding đầu vào (BERT thay bằng **positional embedding học được**). Mỗi khối encoder còn chứa một **Feed-Forward Network** hai lớp:

$$\text{FFN}(x) = \text{GELU}(xW_1 + b_1)W_2 + b_2 \quad (4)$$

cùng kết nối tắt và LayerNorm sau mỗi sub-layer: $\text{LayerNorm}(x + \text{Sublayer}(x))$. Cấu trúc residual + LayerNorm này được lặp lại trong các lớp `_SALayer` của khóa luận (`self.norm = nn.LayerNorm`, áp dụng trên $x + \text{dropout}(\text{attn}(x))$).

2.3. Mô hình ngôn ngữ tiền huấn luyện: BERT và T5

BERT (Bidirectional Encoder Representations from Transformers)

BERT [2] là một encoder Transformer được huấn luyện trước theo hai mục tiêu tự giám sát: **Masked Language Modeling (MLM)** – che ngẫu nhiên 15% token và dự đoán lại dựa trên ngữ cảnh *hai chiều*; và **Next Sentence Prediction (NSP)**. BERT dùng tokenizer **WordPiece**, thêm token [CLS] ở đầu chuỗi (biểu diễn tổng hợp cho phân loại) và [SEP] để phân tách/đánh dấu kết thúc. Đầu ra của BERT là ma trận *hidden states* $H \in \mathbb{R}^{L \times d_h}$ ($d_h = 768$ với bert-base-uncased). Trong cài đặt của khóa luận, H chính là đầu vào cho cả nhánh LCF và nhánh Token Merging.

Hai token [CLS] và [SEP] đóng vai trò quan trọng xuyên suốt pipeline: [CLS] được lớp pooler dùng làm biểu diễn cuối cùng cho phân loại, còn cả hai được **bảo vệ tuyệt đối** (`protect_cls=True`, `protect_sep=True`) khỏi việc bị gộp trong module Token Merging (mục).

T5 (Text-to-Text Transfer Transformer)

T5 là mô hình Transformer theo kiến trúc encoder–decoder, biểu diễn mọi bài toán NLP dưới dạng sinh văn bản (*text-to-text*). T5 được huấn luyện trước trên tập C4 với mục tiêu *span corruption*: một số đoạn liên tiếp bị thay bằng token đặc biệt và mô hình tái tạo lại các đoạn đó.

Trong khóa luận, T5 được dùng cho bài toán ATE. Thay vì gán nhãn chuỗi theo sơ đồ BIO, ATE được hình thức hóa thành bài toán *sinh có điều kiện*. Mô hình T5AspectExtractor (xây trên T5ForConditionalGeneration, backbone t5-base) nhận câu đánh giá và sinh trực tiếp danh sách cụm từ khía cạnh theo định dạng GAS (*Generative Aspect-based Sentiment*). Ví dụ, với câu “*The room was beautiful but the staff was rude.*” mô hình sinh ra “(room); (staff)”; câu không chứa khía cạnh nào sinh ra “none”. Cách tiếp cận sinh xử lý linh hoạt số

lượng khía cạnh không cố định và loại bỏ nhu cầu thiết kế nhãn BIO. Tuy nhiên, đầu ra có thể lệch khỏi văn bản gốc (lỗi chính tả, thiếu/thừa từ), nên được hậu xử lý bằng kỹ thuật **đối sánh n-gram theo khoảng cách Levenshtein** để ánh xạ mỗi cụm từ về chuỗi con gần nhất thực sự xuất hiện trong câu.

Lựa chọn backbone trong khuôn khổ khóa luận

Hệ thống ABSA đầu-cuối gồm hai thành phần ứng với hai bài toán con, mỗi thành phần dùng một mô hình tiền huấn luyện phù hợp:

- **APC**: kiến trúc FAST_LCF_BERT / FastLcfBertMultiTask dùng bert-base-uncased làm backbone. Các module LCF và Token Merging chỉ thao tác trên last_hidden_state $H \in \mathbb{R}^{L \times d_h}$ và kích thước ẩn `hidden_size`, nên kiến trúc không phụ thuộc chặt vào một backbone cụ thể – về nguyên tắc mọi encoder HuggingFace cùng định dạng đầu ra đều có thể thay thế. BERT được chọn để bảo đảm tính phổ biến, khả năng tái lập và chi phí huấn luyện hợp lý.
- **ATE**: dùng t5-base qua T5ForConditionalGeneration, thích hợp cho việc sinh trực tiếp danh sách cụm từ khía cạnh.

Sự kết hợp này tận dụng khả năng biểu diễn ngữ cảnh hai chiều của BERT cho phân loại và khả năng sinh chuỗi linh hoạt của T5 cho trích xuất, tạo thành một hệ thống đầu-cuối sinh bộ ba (*aspect term, aspect category, sentiment*).

2.4. Cơ chế Local Context Focus (LCF)

2.4.1. Động lực: ngữ cảnh cục bộ và ngữ cảnh toàn cục

Trong câu “*The room was beautiful but the staff was rude.*”, từ *beautiful* chỉ mang cảm xúc cho *room*, còn *rude* chỉ liên quan đến *staff*. Nếu mô hình dùng toàn bộ biểu diễn câu (global context) như nhau cho cả hai khía cạnh, thông tin “nhiều” từ khía cạnh kia có thể làm giảm độ chính xác. **Local Context Focus (LCF)** [6] giải quyết vấn đề này: với mỗi khía cạnh, tạo thêm một biểu diễn “ngữ cảnh cục bộ” – trong đó các token xa khía cạnh bị giảm trọng số hoặc loại bỏ – rồi kết hợp biểu diễn cục bộ này với biểu diễn toàn cục gốc.

2.4.2. Khoảng cách ngữ nghĩa tương đối (SRD)

Đầu vào của cơ chế LCF là một vector chỉ thị khía cạnh nhị phân $lcf_vec \in \{0, 1\}^L$, trong đó các vị trí sub-word thuộc cụm từ khía cạnh được gán giá trị 1, các vị trí còn lại bằng 0. Từ vector này, mô hình xác định biên của khía cạnh (a_{start}, a_{end}), tâm và nửa độ rộng:

$$center = \frac{a_{start} + a_{end}}{2}, \quad half = \left\lfloor \frac{a_{end} - a_{start} + 1}{2} \right\rfloor \quad (5)$$

Khoảng cách ngữ nghĩa tương đối (Semantic-Relative Distance – SRD) của token tại vị trí i là khoảng cách từ token đó tới biên của khía cạnh (bằng 0 với mọi token nằm trong cụm khía cạnh):

$$SRD_i = \max(0, |i - center| - half) \quad (6)$$

Một ngưỡng α (siêu tham số `srd_threshold`, mặc định $\alpha = 5$ theo bài báo gốc) được chọn trước: các token có $SRD_i \leq \alpha$ được coi là thuộc “ngữ cảnh cục bộ” của khía cạnh. Trường hợp đặc biệt – nếu câu không chứa token khía cạnh nào – toàn bộ trọng số được đặt bằng 1, tức luồng cục bộ trùng với luồng toàn cục.

Context Dynamic Mask (CDM)

CDM tạo một **mặt nạ nhị phân** $m \in \{0, 1\}^L$, loại bỏ hoàn toàn (đặt về 0) các token nằm ngoài phạm vi α :

$$m_i = \begin{cases} 1, & SRD_i \leq \alpha \\ 0, & SRD_i > \alpha \end{cases} \quad O^{CDM} = H \odot m \quad (7)$$

trong đó $\odot$ là phép nhân theo từng phần tử (mỗi m_i được broadcast trên toàn bộ d_h chiều của token i).

Context Dynamic Weight (CDW)

Thay vì loại bỏ “cứng”, CDW gán trọng số *giảm dần liên tục* theo khoảng cách cho các token ngoài phạm vi α :

$$c_i = \begin{cases} 1, & SRD_i \leq \alpha \\ \frac{L - (SRD_i - \alpha)}{L}, & SRD_i > \alpha \end{cases} \quad O^{CDW} = H \odot c \quad (8)$$

với L là độ dài chuỗi và c_i được kẹp về đoạn $[0, 1]$. CDW giữ lại một phần thông tin từ các token xa khía cạnh (thay vì xóa hoàn toàn như CDM) và cho phép gradient lan truyền mượt hơn. Trong cài đặt của khóa luận, **CDW là biến thể mặc định** (cờ `use_cdm=False`); CDM được dùng để khảo sát đối chứng.

Kết hợp ngữ cảnh cục bộ và toàn cục (Feature Fusion)

Cuối cùng, biểu diễn cục bộ (O^{CDW} hoặc O^{CDM}) và biểu diễn toàn cục (H) được **kết hợp** để mô hình vừa tập trung vào vùng khía cạnh vừa giữ được ngữ cảnh tổng thể.

2.4.3. LCF trong kiến trúc FAST_LCF_BERT của khóa luận

Đầu ra của BERT, $H \in \mathbb{R}^{B \times L \times d}$, được chia thành hai luồng xử lý song song:

1. **Luồng cục bộ (local stream).** Từ SRD và ngưỡng α , mô hình sinh vector trọng số $c \in [0, 1]^L$ (CDW, mặc định) hoặc mặt nạ nhị phân $m \in \{0, 1\}^L$ (CDM), mở rộng về $(B, L, 1)$ để broadcast và nhân với biểu diễn toàn cục: $H_{local} = H \odot c$ (hoặc $H \odot m$). Biểu diễn cục bộ đi qua một lớp Multi-Head Self-Attention (`bert_SA`) nhằm tăng cường tương tác giữa các token trong vùng ngữ cảnh liên quan đến khía cạnh.
2. **Luồng toàn cục (global stream).** Biểu diễn đầu ra của BERT được giữ nguyên, $H_{global} = H$, nhằm bảo toàn ngữ cảnh toàn câu.
3. **Kết hợp đặc trưng.** Hai luồng được ghép nối theo chiều đặc trưng rồi chiếu tuyến tính về lại chiều ẩn:

$$H_{fused} = \text{Linear}_{2d \rightarrow d}([H_{local}; H_{global}]) \quad (9)$$

4. **Mô hình hóa lại ngữ cảnh.** H_{fused} qua dropout và một lớp self-attention thứ hai (`bert_SA_`), tiếp theo là lớp pooling tại token [CLS] (`_SimplePooler: Linear + Tanh`) để thu vector đại diện câu.

5. **Phân loại đa nhiệm.** Vector đại diện được dùng chung cho hai đầu phân loại: `dense_sentiment` (cảm xúc: positive, negative, neutral) và `dense_aspect_cat` (nhóm khía cạnh: SERVICE, FACILITY, AMENITY, EXPERIENCE, BRANDING, LOYALTY).

Ngoài vai trò xây dựng luồng ngữ cảnh cục bộ, vector `lcf_vec` còn được dùng trong module Token Merging (mục) để bảo vệ các token thuộc cụm khía cạnh khỏi bị gộp (`protect_aspect=True`); khi xảy ra gộp, chỉ thị khía cạnh được lan truyền qua phép lấy cực đại (max). Đáng chú ý, Token Merging được áp dụng trên *biểu diễn toàn cục chưa che mặt nạ* trước khi thực hiện LCF, còn LCF chỉ tác động lên luồng cục bộ – nhờ đó mô hình vừa duy trì khả năng tập trung vào vùng khía cạnh, vừa tận dụng lợi ích giảm chi phí tính toán của ToMe.

2.5. Token Merging (ToMe): gộp token sau encoder

2.5.1. Động lực

Như đã chỉ ra ở (2), chi phí self-attention tỉ lệ $O(n^2)$ theo độ dài chuỗi n . Trong ABSA, nhiều token (từ nối, dấu câu, subword lặp) mang rất ít thông tin phân biệt cảm xúc. **Token Merging (ToMe)** [1], ban đầu đề xuất cho Vision Transformer, gộp các token có biểu diễn *tương tự nhau* thành một token đại diện (bằng phép trung bình), giảm độ dài chuỗi mà không cần huấn luyện lại và không thêm tham số. Khóa luận áp dụng ý tưởng này cho chuỗi token 1D (văn bản) **sau backbone BERT, trước khi áp dụng LCF**, qua module `ToMeSequenceMerger`.

Thuật toán gốc: Bipartite Soft Matching

Ý tưởng cốt lõi của ToMe [1] gồm các bước: (1) chia các token (trừ vị trí được bảo vệ) thành hai tập xen kẽ A và B theo chỉ số; (2) chuẩn hóa L_2 vector hidden state; (3) với mỗi $a \in A$, tìm $b \in B$ có độ tương đồng cosine lớn nhất:

$$\text{sim}(a, b) = \frac{\hat{x}_a \cdot \hat{x}_b}{\|\hat{x}_a\| \|\hat{x}_b\|} \quad (10)$$

(4) mỗi $b \in B$ chỉ được ghép tối đa một lần; (5) hai token ghép cặp (a, b) được hợp nhất bằng trung bình:

$$x_{merged} = \frac{1}{2}(x_a + x_b) \quad (11)$$

token b bị loại, token a giữ giá trị x_{merged} . Lặp lại quy trình này qua nhiều vòng (num_merge_steps) sẽ giảm dần độ dài chuỗi.

Cài đặt ToMeSequenceMerger: ba chiến lược gộp

Module ToMeSequenceMerger tổng quát hóa ý tưởng trên thành ba chiến lược (tham số merge_strategy), mỗi vòng giảm độ dài chuỗi khoảng một nửa.

(a) "bipartite" (mặc định). Trong mỗi vòng: xác định **pool nội bộ** (các vị trí không thuộc [CLS], [SEP] và – khi protect_aspect=True – không thuộc vùng khía cạnh); gán xen kẽ pool thành hai nhánh A, B ; mỗi token A chọn token B có cosine (10) lớn nhất (mỗi B tối đa một lần); hợp nhất theo (11). Vector lcf_vec **không** tham gia chọn cặp – sau khi gộp, $lcf[src] = \max(lcf[src], lcf[dst])$.

(b) "sequential_local". Quét chuỗi trái→phải; tại mỗi token i , so sánh cosine với hàng xóm trái và phải gần nhất rồi “gập” về phía hàng xóm giống nhất. Các vị trí **ranh giới LCF** – nơi $lcf_j < 0.5$ và $lcf_{j+1} > 0.5$ (chuyển từ ngoài vào vùng khía cạnh) – được đánh dấu mid_sep và **không** bị gộp, nhằm giữ nguyên ranh giới giữa ngữ cảnh và vùng khía cạnh. Chiến lược này không cần tính ma trận tương đồng toàn cục nên chi phí thấp hơn, nhưng phụ thuộc thứ tự quét.

(c) "attention_weighted". Tận dụng trọng số attention để ưu tiên gộp các token *ít quan trọng nhất*: xếp hạng token theo attention tăng dần; lặp lại việc chọn token attention thấp nhất (chưa bị loại, không thuộc vùng khía cạnh, không thuộc top 25% attention) rồi gộp vào hàng xóm có cosine cao nhất. Bốn nhóm được bảo vệ khỏi bị loại: [CLS], [SEP], token vùng khía cạnh ($lcf > 0.5$), và token attention top 25%. Đây là chiến lược giữ thông tin quan trọng tốt nhất cho ABSA, nhưng đòi hỏi tín hiệu attention làm đầu vào phụ.

Resize: khôi phục độ dài chuỗi


Sau khi gộp, chuỗi có độ dài $L' \leq L$. Trong khóa luận, kết quả gộp luôn được **nội suy tuyến tính trở lại độ dài gốc L** (resize=True, dùng F.interpolate

với `mode="linear"`) cho cả hidden states và `lcf_vec`. Nhờ đó, các lớp phía sau (LCF, self-attention, pooler) giữ nguyên kiến trúc và độ dài đầu vào không đổi, cho phép cô lập và **đo trực tiếp ảnh hưởng của việc gộp token lên chất lượng biểu diễn**, tách biệt khỏi các yếu tố khác.

Kiến trúc tổng thể: FAST_LCF_BERT kết hợp Token Merging

Pipeline tổng thể

Hình 1 minh họa pipeline tổng thể của `FastLcfBertMultiTask`, kết hợp backbone Transformer (mục), Token Merging (mục) và LCF (mục).



Hình 1: Pipeline tổng thể của FastLcfBertMultiTask. Khối ToMe (nét đứt) là thành phần tùy chọn, được chèn ngay sau backbone và trước bước áp dụng LCF; biểu diễn toàn cục H' đi vòng tới bước Fusion.

Vị trí chèn Token Merging và các lựa chọn thiết kế

Một quyết định thiết kế quan trọng là **chèn ToMe ngay sau backbone và trước LCF**, thay vì xen giữa các lớp của backbone hoặc sau toàn bộ pipeline LCF, vì:

- Backbone (BERT) đã được **tiền huấn luyện sẵn**; chèn ToMe vào giữa các lớp sẽ làm thay đổi phân bố đầu vào của các lớp sau, có thể phá vỡ biểu diễn đã học;
- Chèn *trước* LCF cho phép `lcf_vec` được cập nhật đồng bộ theo các token đã gộp (qua quy tắc max, mục), để lớp LCF phía sau vẫn hoạt động đúng ngữ nghĩa trên chuỗi rút gọn;

- Gộp *trước* khi tách biểu diễn cục bộ/toàn cục giúp cả hai nhánh (Fusion) cùng làm việc trên một chuỗi đã rút gọn, tránh phải đồng bộ độ dài.

Việc bảo vệ [CLS], [SEP] và token vùng khía cạnh đảm bảo thông tin *quan trọng nhất cho APC* (vị trí khía cạnh và biểu diễn tổng hợp câu) không bị mất, bất kể chiến lược gộp nào được chọn.

Mở rộng đa nhiệm: FastLcfBertMultiTask

`models/fast_lcf_bert_multitask.py` mở rộng kiến trúc trên thành mô hình **đa nhiệm**, dự đoán đồng thời: **Sentiment** (3 lớp Positive/Negative/Neutral) – nhánh chính, dùng cho mọi mẫu kể cả mẫu bổ trợ (supplement); và **Aspect Category** – chỉ tính loss trên các mẫu chính (`is_supplement=False`) thông qua `main_mask`. Hai nhánh chia sẻ toàn bộ phần thân (backbone $\rightarrow$ ToMe $\rightarrow$ LCF $\rightarrow$ Fusion $\rightarrow$ pooler), chỉ khác ở lớp tuyến tính cuối (`dense_sentiment`, `dense_aspect_cat`). Hàm mất mát tổng:

$$\mathcal{L} = \mathcal{L}_{\text{sentiment}} + \mathbb{1}[\text{main_mask}] \cdot \mathcal{L}_{\text{aspect_cat}} \quad (12)$$

với cả hai thành phần là `CrossEntropyLoss` có **trọng số lớp (class weights)** để xử lý mất cân bằng dữ liệu. Thiết kế đa nhiệm tận dụng tín hiệu giám sát phụ (nhóm khía cạnh) để biểu diễn ẩn học được thông tin tổng quát hơn, có khả năng cải thiện nhánh sentiment chính.

Huấn luyện đa nhiệm và hàm mất mát

Trong ABSA thực tế, cùng một khía cạnh cần dự đoán *cảm xúc* và *nhóm danh mục*. Huấn luyện đa nhiệm (multi-task learning) [?] cho phép hai tác vụ chia sẻ biểu diễn ẩn, tăng tín hiệu giám sát. Với tập mẫu D , mỗi mẫu i có nhãn sentiment $y_i^{(s)}$ và (nếu là mẫu chính) category $y_i^{(c)}$:

$$\mathcal{L}_{\text{total}} = \frac{1}{|D|} \sum_{i \in D} \left(w_s \cdot \ell_{\text{CE}}(f_s(h_i), y_i^{(s)}) + w_c \cdot \mathbb{1}[\neg \text{supp}_i] \cdot \ell_{\text{CE}}(f_c(h_i), y_i^{(c)}) \right) \quad (13)$$

trong đó h_i là vector pooler từ `FastLcfBertMultiTask`, f_s, f_c là hai đầu tuyến

tính, ℓ_{CE} là cross-entropy có trọng số lớp (inverse frequency) để giảm ảnh hưởng mất cân bằng. Mẫu supplement chỉ tham gia hạng thứ nhất.

Độ đo đánh giá trong ABSA

Đánh giá trích xuất khía cạnh (ATE)

ATE được đánh giá bằng **exact match**: một cụm từ dự đoán đúng khi khớp hoàn toàn chuỗi gold (sau chuẩn hóa). Precision, Recall và F1 được tính ở mức micro trên tập các cặp (câu, term).

Đánh giá bộ ba (Joint Triplet)

Nhãn đánh giá ghép: $\ell = \langle \text{sentiment} \rangle_ \langle \text{category} \rangle$ (ví dụ `positive_SERVICE`). Một bộ ba (a, c, s) là **True Positive** khi aspect term a , category c và sentiment s *đồng thời* khớp gold:

$$TP \Leftrightarrow (a = a^*) \wedge (c = c^*) \wedge (s = s^*) \quad (14)$$

Micro F1 tổng hợp TP/FP/FN toàn cục – nhạy với nhãn phổ biến. **Macro F1** lấy trung bình F1 từng lớp – phản ánh nhãn thiểu số. **Oracle Joint Acc** cho trước aspect term gold, đo *trần* của bộ phân loại, tách biệt lỗi ATE trong Pipeline.

Các hướng tiếp cận liên quan

Phân loại tuần tự và mô hình sinh

Trước kỷ nguyên Transformer, ABSA dùng feature thủ công + SVM/LSTM. BERT [2] mở ra phân loại SPC: ghép câu và aspect term [CLS] sent [SEP] aspect [SEP]. FAST-LCF-BERT [6, ?] bổ sung luồng ngữ cảnh cục bộ. GAS [?] chuyển sang sinh có điều kiện một bước – module gas/ trong repo là biến thể liên quan; đề tài dùng T5 riêng cho ATE và BERT/T5+LCF cho APC.

Token Merging và hiệu năng Transformer

ToMe [1] giảm token trong ViT bằng ghép cặp bipartite cosine. Áp dụng cho NLP 1D đòi hỏi bảo vệ token ngữ nghĩa (khía cạnh, CLS). Khóa luận đề xuất `sequential_local` và `attention_weighted` nhằm giảm rủi ro gộp nhầm vùng aspect – chi tiết hiện thực ở Chương .

Tách câu và ngữ cảnh cục bộ

UOS (Unit Opinion Sentence) tách câu dài trước inference (`uos/`, `clause_splitting.p`). LCF và UOS cùng hướng tới *thu hẹp ngữ cảnh*, nhưng LCF làm việc trong embedding space còn UOS ở mức văn bản thô – đánh giá so sánh ở Bước 5 (Chương ??).

Tóm tắt chương

Chương này đã trình bày chuỗi nền tảng lý thuyết theo đúng trình tự xuất hiện trong kiến trúc cài đặt: (1) bài toán ABSA và các bài toán con, với trọng tâm là APC trên dữ liệu đánh giá khách sạn; (2) kiến trúc Transformer và self-attention – nền tảng tính toán của BERT/T5, đồng thời là nguồn gốc của chi phí $O(n^2)$ mà Token Merging hướng tới giảm bớt; (3) hai mô hình tiền huấn luyện BERT (cho APC) và T5 (cho ATE); (4) cơ chế Local Context Focus với SRD, hai biến thể CDM/CDW và bước Fusion, trong đó cài đặt của khóa luận dùng **CDW làm mặc định**; (5) Token Merging với ba chiến lược gộp (`bipartite`, `sequential_local`, `attention_weighted`), trong đó chuỗi sau khi gộp luôn được nội suy trở lại độ dài gốc (`resize`) để cô lập và đánh giá ảnh hưởng của việc gộp lên chất lượng biểu diễn; và (6) kiến trúc tổng thể `FastLcfBertMultiTask`, nơi ToMe được chèn giữa backbone và LCF, cùng mở rộng đa nhiệm sentiment + aspect category. Đây là cơ sở để chương tiếp theo trình bày chi tiết phương pháp luận, thiết lập thực nghiệm và các kịch bản so sánh baseline với các biến thể Token Merging.

Phương pháp thực hiện

Chương này trình bày cách hệ thống được thiết kế và hiện thực. Mục mô tả kiến trúc tổng thể dưới dạng một chuỗi các *stage* xử lý, giải thích vai trò của từng stage và đi sâu vào chi tiết stage phân loại. Mục trình bày hai phương pháp kỹ thuật cốt lõi được tích hợp vào kiến trúc – cơ chế tập trung ngữ cảnh cục bộ (LCF) và kỹ thuật gộp token (Token Merging). Các mục còn lại trình bày bộ dữ liệu, hàm mất mát, thiết lập huấn luyện và phương pháp đánh giá. Mọi mô tả đều được đối chiếu trực tiếp với mã nguồn trong repo.

Kiến trúc tổng thể


Bài toán và luồng xử lý đầu-cuối

Hệ thống giải quyết bài toán **trích xuất bộ ba** (*Joint Triplet Extraction*): từ một câu đánh giá khách sạn x , trích xuất tập

$$\mathcal{T} = \{(a_i, c_i, s_i)\}_{i=1}^m \quad (15)$$

với a_i là *aspect term* (cụm từ khía cạnh), c_i là *aspect category* (AMENITY, BRANDING, EXPERIENCE, FACILITY, LOYALTY, SERVICE) và s_i là cực tính (*Positive / Negative / Neutral*). Một bộ ba được tính đúng khi và chỉ khi **cả ba thành phần** khớp nhãn gold.

Hệ thống được tổ chức thành bốn stage nối tiếp (Hình 2): tiền xử lý, trích xuất khía cạnh (ATE), phân loại nhóm khía cạnh và cảm xúc (APC), và tổng hợp bộ ba.



Hình 2: Kiến trúc tổng thể của hệ thống trích xuất bộ ba, tổ chức thành bốn stage nối tiếp. Đường `aspect terms` từ Stage 2 sang Stage 3 là luồng của kiến trúc Pipeline; ở kiến trúc Joint, `aspect term` được lấy trực tiếp từ nhãn gold (mục).

Giải thích từng stage

Stage 1 — Tiền xử lý và biểu diễn đầu vào. Mỗi mẫu được token hóa theo định dạng **Sentence-Pair Classification (SPC)**, ghép câu (segment A) với cụm khía cạnh (segment B): `[CLS] <câu> [SEP] <aspect term> [SEP]`, độ dài tối đa $L = 128$. Đồng thời, hệ thống dựng **vector chỉ thị khía cạnh** `lcf_vec` $\in \{0, 1\}^L$: dựa trên `offset_mapping` của tokenizer, mỗi token thuộc segment A có khoảng ký tự *giao* với khoảng ký tự của cụm khía cạnh được gán 1, còn lại bằng 0. Nếu cụm khía cạnh bị cắt khỏi segment A, hệ thống quay lui dùng `token_type_ids` (bản sao khía cạnh ở segment B) làm chỉ thị. Vector này là tín hiệu đầu vào cho phương pháp LCF (mục).

Stage 2 — Trích xuất khía cạnh (ATE) bằng T5. Bài toán ATE được hình thức hóa thành **sinh có điều kiện**: mô hình `T5AspectExtractor` (backbone `t5-base`) nhận câu và sinh trực tiếp danh sách cụm từ khía cạnh theo định dạng GAS, ví dụ `"(phòng); (nhân viên); (thang máy)"`; câu không có khía cạnh sinh ra `"none"`. Quá trình sinh dùng beam search (`beam = 4`, `max_len = 64`). Vì chuỗi sinh có thể lệch khỏi văn bản gốc, đầu ra được **chuẩn hóa bằng đối sánh n-gram**

theo khoảng cách Levenshtein, ánh xạ mỗi cụm từ về chuỗi con gần nhất thực sự xuất hiện trong câu.

Stage 3 — Phân loại (APC) đa nhiệm. Với mỗi cặp (câu, aspect term), mô hình FastLcfBertMultiTask dự đoán đồng thời nhóm khía cạnh và cảm xúc. Đây là stage trung tâm, nơi hai phương pháp LCF và Token Merging được tích hợp; chi tiết kiến trúc được trình bày ở mục .

Stage 4 — Tổng hợp bộ ba. Aspect term (từ Stage 2 hoặc nhãn gold) được ghép với nhóm khía cạnh và cảm xúc (từ Stage 3) thành các bộ ba (a_i, c_i, s_i) – đầu ra cuối cùng của hệ thống.

Hai kiến trúc tổ chức: Joint và Pipeline


Khóa luận khảo sát hai cách kết nối Stage 2 và Stage 3 (Bảng 2):

Bảng 2: Hai kiến trúc tổ chức bài toán đầu-cuối

Kiến trúc	Mô tả	Đặc điểm
Joint	APC được đánh giá trên aspect term <i>gold</i> ; ATE và APC không phụ thuộc đầu ra của nhau	Cô lập được năng lực bộ phân loại, không chịu lan truyền lỗi
Pipeline	T5 thực hiện ATE trước, aspect term <i>dự đoán</i> được đưa sang APC	Linh hoạt, phản ánh hiệu suất thực tế; chịu lan truyền lỗi từ ATE

Chi tiết kiến trúc Stage APC

Hình 3 mô tả chi tiết stage phân loại. Đầu ra `last_hidden_state` $H \in \mathbb{R}^{L \times d_h}$ của backbone đi qua khối **Token Merging** (tùy chọn), sau đó tách thành **hai luồng**: luồng cục bộ (nhân với trọng số LCF) và luồng toàn cục (giữ nguyên). Hai luồng được hợp nhất, đưa qua self-attention và pooler, rồi vào hai đầu phân loại.



Hình 3: Chi tiết kiến trúc Stage APC (FastLcfBertMultiTask). Khối Token Merging (nét đứt) là tùy chọn; biểu diễn toàn cục đi vòng tới bước Fusion. Hai đầu phân loại chia sẻ chung phần thân.

Các phương pháp

Hai phương pháp kỹ thuật được tích hợp vào Stage APC nhằm hai mục tiêu bổ trợ nhau: **LCF** (mục) tăng độ chính xác phân loại bằng cách tập trung vào ngữ cảnh quanh khía cạnh; **Token Merging** (mục) giảm chi phí tính toán bằng cách rút ngắn chuỗi token. Nền tảng lý thuyết của hai phương pháp đã trình bày ở Chương ; phần này tập trung vào cách *áp dụng và hiện thực* chúng trong hệ thống.

Phương pháp 1: Tập trung ngữ cảnh cục bộ (LCF)

Ý tưởng. Với mỗi khía cạnh, các từ ở gần thường mang thông tin cảm xúc liên quan hơn các từ ở xa. LCF [6, ?] khai thác điều này bằng cách tạo thêm một luồng

biểu diễn “cục bộ” trong đó token xa khía cạnh bị giảm trọng số, rồi kết hợp với luồng toàn cục.

Khoảng cách ngữ nghĩa tương đối (SRD). Từ vector `lcf_vec` (dùng ở Stage 1), hệ thống xác định tâm và nửa độ rộng của cụm khía cạnh, rồi tính SRD của token tại vị trí i :

$$SRD_i = \max\left(0, |i - \text{center}| - \text{half}\right), \quad \text{half} = \left\lfloor \frac{a_{\text{end}} - a_{\text{start}} + 1}{2} \right\rfloor \quad (16)$$

với ngưỡng $\alpha = 5$ (SRD_THRESHOLD): token có $SRD_i \leq \alpha$ thuộc ngữ cảnh cục bộ.

Hai biến thể tạo trọng số. Hệ thống cài đặt hai biến thể, chọn qua cờ `use_cdm`:

- **CDW** (Context Dynamic Weight – mặc định): trọng số giảm dần liên tục, $c_i = 1$ nếu $SRD_i \leq \alpha$, ngược lại $c_i = (L - (SRD_i - \alpha)) / L$ (kẹp về $[0, 1]$);
- **CDM** (Context Dynamic Mask): mặt nạ nhị phân, $m_i = 1$ nếu $SRD_i \leq \alpha$, ngược lại $m_i = 0$.

Tích hợp hai luồng. Luồng cục bộ $H_{\text{local}} = H \odot c$ (hoặc $H \odot m$) qua self-attention `bert_SA`; luồng toàn cục H giữ nguyên. Hai luồng được hợp nhất:

$$H_{\text{fused}} = \text{Linear}_{2d \rightarrow d}([H_{\text{local}}; H]) \quad (17)$$

trước khi qua self-attention thứ hai và pooler (xem Hình 3).

Phương pháp 2: Gộp token (Token Merging – ToMe)

Ý tưởng. Chi phí self-attention tỉ lệ $O(n^2)$ theo độ dài chuỗi n ; nhiều token (từ nối, dấu câu, subword lặp) mang ít thông tin phân biệt cảm xúc. ToMe [1] gộp các token có biểu diễn tương tự nhau (đo bằng cosine) thành một token đại diện bằng phép trung bình, rút ngắn chuỗi mà không thêm tham số. Trong hệ thống, ToMe được áp dụng **sau backbone, trước LCF** (module `ToMeSequenceMerger`).

Ba chiến lược gộp. Lựa chọn qua tham số `merge_strategy`:

Bảng 3: Ba chiến lược gộp token được khảo sát

Chiến lược	Cơ chế
<code>bipartite</code>	Chia token nội bộ thành hai nhóm xen kẽ A, B ; mỗi token A ghép với token B tương đồng cosine nhất (phương pháp gốc, CVPR 2023).
<code>sequential_local</code>	Quét trái→phải, mỗi token gộp về phía hàng xóm (trái/phải) giống nhất; giữ nguyên ranh giới vào vùng khía cạnh.
<code>attention_weight</code>	Huấn luyện gộp token có trọng số attention thấp nhất; bảo vệ token khía cạnh và token attention cao (top 25%).

Bảo vệ token quan trọng. Cả ba chiến lược đều bảo vệ tuyệt đối `[CLS]`, `[SEP]` và token thuộc vùng khía cạnh (`protect_aspect=True`). Khi xảy ra gộp, chỉ thị khía cạnh được lan truyền qua phép lấy cực đại: $\text{lcf}[\text{src}] = \max(\text{lcf}[\text{src}], \text{lcf}[\text{dst}])$ – nhờ đó LCF ở bước sau vẫn hoạt động đúng trên chuỗi đã rút gọn.

Khôi phục độ dài (resize). Sau khi gộp, chuỗi có độ dài $L' \leq L$. Trong khóa luận, kết quả gộp **luôn được nội suy tuyến tính trở lại độ dài gốc L** (`resize=True`, dùng `F.interpolate` với `mode="linear"`) cho cả hidden states và `lcf_vec`. Nhờ đó các lớp phía sau (LCF, self-attention, pooler) giữ nguyên kiến trúc và độ dài đầu vào không đổi qua mọi cấu hình.

Vì sao chỉ dùng `resize` mà không dùng `compact`

Module `ToMeSequenceMerger` có hỗ trợ chế độ *compact* (`resize=False`) – giữ nguyên chuỗi rút gọn độ dài L' và đếm theo $L'_{\max}$ của batch. Tuy nhiên, **toàn bộ thực nghiệm của khóa luận chỉ dùng `resize=True`**, vì ba lý do sau:

1. **Cô lập đúng biến cần đo.** Câu hỏi nghiên cứu đối với ToMe là *liệu việc gộp token dư thừa có làm suy giảm chất lượng phân loại không, và chiến lược gộp nào bảo toàn thông tin tốt nhất* – một câu hỏi về *chất lượng biểu diễn*. Chế độ `resize` giữ độ dài chuỗi cố định ở $L = 128$ qua mọi cấu hình, nên khác biệt duy nhất giữa baseline và một cấu hình có gộp là *nội dung biểu*

diễn (do trung bình các token tương đồng). Mọi thay đổi về độ chính xác vì thế quy hoàn toàn về thao tác gộp, không bị nhiễu bởi độ dài chuỗi hay cách đệm khác nhau.

2. **Compact gây nhiễu so sánh.** Ở chế độ compact, mỗi cấu hình (và mỗi câu) sinh ra độ dài L' khác nhau, buộc phải đệm theo $L'_{\max}$ của batch. Điều này trộn lẫn ảnh hưởng của việc gộp với ảnh hưởng của độ dài chuỗi thay đổi, khiến không thể quy kết sạch chênh lệch độ chính xác cho riêng chiến lược gộp.
3. **Lợi ích tốc độ của compact ở vị trí này là không đáng kể.** ToMe được chèn sau backbone (mục), nên 12 lớp Transformer của backbone – phần tốn kém nhất – vẫn luôn chạy ở độ dài đầy đủ $L = 128$ bất kể chế độ nào. Compact chỉ rút ngắn đầu vào cho hai lớp self-attention nhẹ phía sau, vốn chiếm tỉ lệ nhỏ trong tổng chi phí. Do đó compact gần như không mang lại tăng tốc thực sự, trong khi lại làm phức tạp việc so sánh.

Vì những lý do trên, khóa luận giới hạn phạm vi thực nghiệm ở **câu hỏi chất lượng biểu diễn** (dùng resize). Câu hỏi *tăng tốc suy luận* thực sự – vốn đòi hỏi gộp token trước backbone (pre-BERT ToMe, để chuỗi ngắn đi vào ngay 12 lớp Transformer) hoặc dùng compact ở vị trí thích hợp – được để lại cho hướng phát triển (Chương 5).

Huấn luyện đa nhiệm

Hai đầu phân loại được huấn luyện đồng thời bằng tổng hai thành phần CrossEntropyLoss

$$\mathcal{L} = w_s \mathcal{L}_{\text{sentiment}} + w_c \mathbb{1}[\text{main_mask}] \cdot \mathcal{L}_{\text{aspect_cat}} \quad (18)$$

trong đó $\mathbb{1}[\text{main_mask}]$ là hàm chỉ thị chỉ bật trên mẫu chính (`is_supplement=False`) – đầu phân loại nhóm khía cạnh **không** học trên mẫu hỗ trợ (vốn không có nhãn category). Cấu hình chính dùng $w_s = w_c = 1.0$. Cả hai thành phần dùng **trọng số lớp theo tần suất nghịch đảo** $w_k = N/(C \cdot n_k)$ (N : tổng số mẫu, C : số lớp, n_k : số mẫu lớp k) để giảm ảnh hưởng của mất cân bằng dữ liệu. Giá trị siêu tham số và quy trình huấn luyện cụ thể được trình bày ở Chương 4.

Ví dụ minh họa chi tiết các phương pháp

Để làm rõ cơ chế của hai phương pháp, mục này trình bày một **ví dụ chạy xuyên suốt** với các vector “đồ chơi” (toy vectors) 4 chiều thay cho hidden states 768 chiều thực tế. Các con số được chọn để minh họa, song mọi công thức và quy tắc đều đúng với mã nguồn.

Thiết lập chung

Xét câu “*I found the food delicious but service was terrible*” với khía cạnh **food** (gold: *positive*, FOOD). Sau token hóa SPC, chuỗi gồm 13 token hợp lệ ([CLS] + câu + [SEP] + food + [SEP]), phần còn lại là padding. Bảng 4 liệt kê vị trí, token, vector ần v_i và giá trị `lcf_vec` (chỉ token khía cạnh ở segment A được gán 1).

Bảng 4: Thiết lập ví dụ: 13 token hợp lệ với vector ần 4 chiều

Vị trí	Token	Vector v_i	<code>lcf_vec</code>
0	[CLS]	[1, 0, 1, 0]	0
1	i	[1, 1, 0, 1]	0
2	found	[2, 1, 2, 1]	0
3	the	[1, 0, 1, 1]	0
4	food (aspect)	[5, 4, 3, 2]	1
5	delicious	[4, 3, 2, 2]	0
6	but	[1, 0, 2, 0]	0
7	service	[3, 2, 1, 2]	0
8	was	[1, 1, 2, 0]	0
9	terrible	[3, 1, 0, 3]	0
10	[SEP] _{mid}	[1, 0, 2, 1]	0
11	food _B (bản sao)	[5, 4, 3, 2]	0
12	[SEP] _{end}	[0, 1, 0, 1]	0

Ví dụ Phương pháp 1a – LCF-CDW

Khía cạnh nằm tại $a_{start} = a_{end} = 4$, nên $center = 4$, $half = \lfloor 1/2 \rfloor = 0$, và $SRD_i = |i - 4|$. Với $\alpha = 5$ và $L = 128$, trọng số CDW là 1 cho mọi token có $|i - 4| \leq 5$ (vị trí 0–9) và giảm nhẹ cho các vị trí xa hơn (Bảng 5).

Bảng 5: Trọng số CDW cho các vị trí có $SRD > \alpha$

Vị trí	SRD_i	$c_i = \frac{L-(SRD_i-\alpha)}{L}$	Kết quả $v_i \cdot c_i$
0–9	≤ 5	1.000	giữ nguyên
10	6	$127/128 = 0.992$	$[0.99, 0, 1.98, 0.99]$
11	7	$126/128 = 0.984$	$[4.92, 3.94, 2.95, 1.97]$
12	8	$125/128 = 0.977$	$[0, 0.98, 0, 0.98]$

Nhận xét: vì $L = 128$ lớn, CDW chỉ giảm trọng số rất nhẹ (còn ≈ 0.98) ngay cả với token xa nhất – token xa vẫn đóng góp, chỉ ít hơn. Với câu dài hơn (ví dụ 23 token, khía cạnh ở đầu câu), các token cuối có thể giảm xuống ≈ 0.89 : CDW *giảm mượt* theo khoảng cách.

Ví dụ Phương pháp 1b – LCF-CDM

CDM dùng cùng SRD nhưng cắt cứng: $m_i = 1$ nếu $SRD_i \leq 5$, ngược lại $m_i = 0$ (không phụ thuộc L). Trên ví dụ, các vị trí 10–12 bị **xóa hoàn toàn** (Bảng 6).

Bảng 6: So sánh CDW và CDM tại các vị trí 10–12

Vị trí	Token	CDW	CDM
10	$[\text{SEP}]_{\text{mid}}$	$[0.99, 0, 1.98, 0.99]$	$[0, 0, 0, 0]$
11	food_B	$[4.92, 3.94, 2.95, 1.97]$	$[0, 0, 0, 0]$
12	$[\text{SEP}]_{\text{end}}$	$[0, 0.98, 0, 0.98]$	$[0, 0, 0, 0]$

Nhận xét: với câu ngắn, chênh lệch giữa CDM và CDW nhỏ (chỉ 3 token cuối). Với câu dài, CDM có thể cắt hơn 15 token – luồng cục bộ chỉ còn đúng vùng câu quanh khía cạnh, bỏ hẳn $[\text{SEP}]$ và bản sao segment B. Đây là lý do CDM thường tốt hơn cho nhãn thiếu số (tập trung “cứng”), còn CDW giữ nhiều thông tin toàn cục hơn.

Ví dụ Phương pháp 2a – ToMe Bipartite

Token được bảo vệ: $[\text{CLS}]$ (vị trí 0), $[\text{SEP}]_{\text{end}}$ (vị trí 12) và token khía cạnh **food** (vị trí 4). Pool nội bộ còn lại gồm 10 vị trí $\{1, 2, 3, 5, 6, 7, 8, 9, 10, 11\}$. Chia xen kẽ *theo thứ hạng trong pool*¹:

¹Theo `torch.arange(0,nm,2)` và `arange(1,nm,2)` trong `_bipartite_pairs` – chia theo thứ hạng, không theo chẵn/lẻ của vị trí token.

$$A = \{1, 3, 6, 8, 10\}, \quad B = \{2, 5, 7, 9, 11\}.$$

Mỗi token nhóm A chọn token nhóm B có cosine lớn nhất. Ví dụ với vị trí 1 (i) và vị trí 7 (*service*):

$$\cos(v_1, v_7) = \frac{[1, 1, 0, 1] \cdot [3, 2, 1, 2]}{\sqrt{3} \sqrt{18}} = \frac{7}{7.35} \approx 0.95.$$

Bảng 7 trình bày kết quả chọn cặp và khử trùng (mỗi token B chỉ được ghép một lần, duyệt A theo thứ tự).

Bảng 7: Bipartite – chọn cặp và khử trùng (bước 1)

Token A	B tương đồng nhất	cos	Kết quả
1 (i)	7 (service)	0.95	✓ ghép $1 \leftarrow 7$
3 (the)	2 (found)	0.91	✓ ghép $3 \leftarrow 2$
6 (but)	2 (found)	0.85	× ($B=2$ đã dùng)
8 (was)	2 (found)	0.90	× ($B=2$ đã dùng)
10 ([SEP])	2 (found)	0.90	× ($B=2$ đã dùng)

Hai cặp được gộp bằng trung bình: vị trí 1 hấp thụ vị trí 7 ($x_1 \leftarrow \frac{1}{2}(v_1 + v_7)$), vị trí 3 hấp thụ vị trí 2; hai token 2 và 7 bị loại $\Rightarrow$ chuỗi còn **11 token**. Vì $\text{TOME_MERGE_STEPS} = 2$, quá trình lặp lại trên 11 token và rút xuống ≈ 9 **token**. Chỉ thị khía cạnh được lan truyền qua phép max (ở đây cả hai cặp đều có $\text{lcf} = 0$ nên không đổi).

Ví dụ Phương pháp 2b – ToMe Sequential Local

Chiến lược này quét trái $\rightarrow$ phải, mỗi token gập về phía hàng xóm giống nhất. Trước hết, ranh giới vào vùng khía cạnh được phát hiện: tại vị trí 3 có $\text{lcf}_3=0$ và $\text{lcf}_4=1$ nên vị trí 3 (*the*) được đánh dấu *mid_sep* và *không* bị gộp.

Khi quét tới vị trí 5 (*delicious*):

$$\begin{aligned} \cos(v_5, v_4) &= \frac{[4, 3, 2, 2] \cdot [5, 4, 3, 2]}{\sqrt{33} \sqrt{54}} = \frac{42}{42.2} \approx 0.995 \quad (\text{trái}), \\ \cos(v_5, v_6) &= \frac{[4, 3, 2, 2] \cdot [1, 0, 2, 0]}{\sqrt{33} \sqrt{5}} = \frac{8}{12.8} \approx 0.62 \quad (\text{phải}). \end{aligned}$$

Vì sim trái lớn hơn, *delicious* gộp vào **food** (vị trí 4): $x_4 \leftarrow \frac{1}{2}(v_4 + v_5)$ và quan trọng là $\text{lcf}_4 = \max(1, 0) = 1$ – **tín hiệu khía cạnh được giữ nguyên**. Token khía cạnh không bị xóa nhưng *có thể nhận* các token gộp vào. Do hiệu ứng **xếp tầng (cascade)** trong một lượt quét, các token kế tiếp (*but, service, was, terrible, ...*) lần lượt gộp vào vị trí 4, khiến chuỗi rút mạnh xuống ≈ 5 token chỉ sau **một lượt**. Sequential do đó gộp mạnh hơn bipartite (không bị giới hạn bởi số bước).

Ví dụ Phương pháp 2c – ToMe Attention-Weighted

Trong huấn luyện, vòng lặp không truyền trọng số attention nên `attn_seg` đồng nhất ($= 1$). Khi đó thuật toán chọn token *chưa bị loại, không được bảo vệ, không phải khía cạnh* theo thứ tự, rồi gộp nó vào hàng xóm cosine cao nhất. Ví dụ ở vòng 1, vị trí 1 (i) được chọn; cosine cao nhất là với vị trí 7 (*service*, ≈ 0.95) nên i bị xóa và $x_7 \leftarrow \frac{1}{2}(v_7 + v_1)$ (xóa i , cập nhật j bằng trung bình). Giới hạn $\lfloor (13 - 2)/2 \rfloor = 5$ lần gộp, chuỗi rút xuống **8 token**; token khía cạnh **food** luôn được bảo vệ.

Ví dụ tổ hợp: LCF-CDM + Bipartite + resize

Cuối cùng, ghép các bước thành luồng đầy đủ của một cấu hình (ví dụ `use_lcf=True, use_cdm=True, use_tome=True, tome_resize=True, merge_strategy="bipartite"`):

1. **Backbone** sinh $H \in \mathbb{R}^{128 \times d_h}$ (13 hàng hợp lệ, còn lại padding).
2. **ToMe bipartite** rút $13 \rightarrow 9$ token, rồi **resize** nội suy tuyến tính trở lại 128 hàng. Vector `lcf_vec` cũng được nội suy nên không còn nhị phân: vùng khía cạnh “loang” thành một dải quanh vị trí tương ứng.
3. **CDM** tính lại từ `lcf_vec` đã resize: tìm vùng $\text{lcf} > 0.5$, suy ra center/half và mặt nạ; chỉ một cửa sổ cục bộ quanh khía cạnh được giữ ($m_i = 1$), phần còn lại bằng 0.
4. **Luồng cục bộ** $H_{\text{local}} = H \odot m$; **luồng toàn cục** giữ nguyên H .
5. **Fusion** $\rightarrow$ self-attention $\rightarrow$ pooler $\rightarrow$ hai đầu phân loại, cho `sentiment_logits` (3 lớp) và `aspect_cat_logits` (6 lớp); `arg max` cho *positive* và *FOOD*.

Hai điểm cần nhấn mạnh:

- **ToMe không tạo đặc trưng mới** – nó chỉ *giảm số token* bằng cách trung bình các token tương đồng; đầu ra của ToMe được dùng ngay cho LCF, không qua lớp biến đổi nào khác.
- **Token [CLS] đưa vào pooler là từ biểu diễn đã hợp nhất** (H_{fused} sau Fusion + self-attention), *không phải* [CLS] thô của backbone – tức quyết định phân loại dựa trên cả luồng cục bộ lẫn toàn cục.

Tóm tắt chương

Chương này đã trình bày phương pháp thực hiện theo hai trục chính: (1) **kiến trúc tổng thể** gồm bốn stage nối tiếp – tiền xử lý, ATE (T5), APC (FastLcfBertMultiTask) và tổng hợp bộ ba – cùng chi tiết kiến trúc stage phân loại và hai cách tổ chức Joint/Pipeline; (2) **hai phương pháp kỹ thuật** tích hợp vào stage APC: LCF (với SRD và hai biến thể CDM/CDW) nhằm tập trung ngữ cảnh cục bộ, và Token Merging (ba chiến lược) nhằm giảm dư thừa token. Chương cũng làm rõ **lý do toàn bộ thực nghiệm chỉ dùng chế độ resize** (cô lập câu hỏi chất lượng biểu diễn) và hàm mất mát đa nhiệm có trọng số lớp. Bộ dữ liệu, thiết lập huấn luyện, không gian cấu hình và kết quả thực nghiệm được trình bày ở Chương 4.

IV. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương này trình bày toàn bộ quá trình thiết lập thực nghiệm, kết quả đánh giá định lượng và phân tích chuyên sâu các biến thể mô hình được đề xuất. Mục tiêu là kiểm chứng hai câu hỏi nghiên cứu chính: (1) Kỹ thuật Token Merging (ToMe) có cải thiện hiệu suất phân loại khía cạnh–cảm xúc so với baseline không? (2) Chiến lược merging dựa trên trọng số attention có ưu việt hơn bipartite matching truyền thống trong ngữ cảnh câu ngắn ABSA không?

1. Môi trường thực nghiệm

1.1 Phần cứng và phần mềm

Tất cả các thí nghiệm được thực hiện trên một máy chủ GPU duy nhất với cấu hình như sau:

Bảng 8: Cấu hình môi trường thực nghiệm

Thành phần	Thông số
GPU	NVIDIA Tesla T4 (15 GB VRAM) * 2
CPU	Intel Xeon, 4 nhân ảo, max 30 GB RAM
Hệ điều hành	Ubuntu 22.04 (Kaggle)
Python	3.12
PyTorch	2.0+ (CUDA 12)
Transformers	HuggingFace 4.36+

1.2 Tập dữ liệu

Nghiên cứu này sử dụng tập dữ liệu thuộc miền khách sạn / du lịch, gồm các đánh giá (review) của khách lưu trú tại các khách sạn ở Việt Nam, được lưu theo định dạng .csv. Tập dữ liệu phục vụ bài toán Aspect-Based Sentiment Analysis (ABSA) với bốn trường (normalized_text, aspect term, aspect category, sentiment).

Bảng 9: Danh mục các khía cạnh trong lĩnh vực khách sạn

Khía cạnh	Mô tả
Cơ sở vật chất (Facility)	Bao gồm các yếu tố như thiết bị, nội thất phòng, trang trí khách sạn, thiết kế nội thất, ban công và khu vực hồ bơi.
Tiện ích (Amenity)	Bao gồm các dịch vụ công cộng như bãi đậu xe, spa, nhà hàng, quà lưu niệm, các điểm đến lân cận, các tùy chọn thanh toán và sự an ninh.
Dịch vụ (Service)	Liên quan đến chất lượng dịch vụ của khách sạn, chất lượng món ăn và thái độ của nhân viên.
Trải nghiệm (Experience)	Liên quan đến trải nghiệm của khách hàng về khách sạn như bầu không khí và cảm nhận về mức độ thư giãn mà khách sạn mang lại.
Thương hiệu (Branding)	Phản ánh mức độ hài lòng chung của khách hàng so với thương hiệu được cung cấp.
Mức độ trung thành (Loyalty)	Cho biết khả năng khách hàng quay lại và giới thiệu khách sạn cho người khác.

Cảm xúc phân cực (Polarity Sentiment): Là nhãn cảm xúc cuối cùng được gán cho mệnh đề, thuộc một trong ba giá trị:

Bảng 10: Các nhóm phân cực cảm xúc

Nhóm cảm xúc	Mô tả
Tích cực (Positive)	Bao gồm các cảm xúc như hài lòng, vui vẻ và hạnh phúc.
Tiêu cực (Negative)	Bao gồm các cảm xúc như không hài lòng, thất vọng, phàn nàn và khó chịu.
Trung tính (Neutral)	Bao gồm các cảm xúc không mang ý nghĩa tích cực hoặc tiêu cực, cảm xúc bình thường và không có cảm xúc đặc biệt.

Bảng 11: Thống kê tập dữ liệu En

Phân tập	Số mẫu	Số câu gốc	Ghi chú
Train	2,448	2,322	Huấn luyện mô hình
Dev	304	303	Dùng cho early stopping
Test	312	309	Đánh giá cuối cùng

Phân phối nhãn cảm xúc (tập Train). Tập dữ liệu có sự mất cân bằng nhãn nghiêm trọng (Bảng 10).

Bảng 12: Phân phối nhãn cảm xúc trên tập Train

Nhãn cảm xúc	Số mẫu	Tỉ lệ (%)
Positive	2,237	91,4
Negative	168	6,9
Neutral	43	1,8
Tổng	2,448	100,0

Để giải quyết vấn đề này, nghiên cứu áp dụng **weighted cross-entropy loss** với trọng số tỉ lệ nghịch với tần suất lớp nhằm tăng cường tín hiệu học cho hai nhãn thiếu số *Negative* và *Neutral*.

Phân phối nhãn category (6 lớp). Sáu danh mục khía cạnh trong tập En được trình bày trong Bảng 13. Các danh mục LOYALTY và BRANDING xuất hiện ít hơn đáng kể so với FACILITY và SERVICE, tạo thêm thách thức cho việc phân loại.

1.2 Tập dữ liệu

Nghiên cứu này sử dụng tập dữ liệu **SemEval-2016 Task 5 – REST16** (miền nhà hàng), vốn là chuẩn đánh giá phổ biến nhất cho bài toán Aspect-Based Sentiment Analysis (ABSA). Dữ liệu được định dạng theo chuẩn 4 dòng .apc (một mẫu = 4 dòng liên tiếp: câu với ký hiệu \$T\$, aspect term, aspect category, nhãn cảm xúc).

Phân phối nhãn cảm xúc (tập Train). Tập dữ liệu có sự mất cân bằng nhãn nghiêm trọng: *Positive* chiếm 91,4% (2 237 mẫu), *Negative* chiếm 6,9% (168 mẫu),

Bảng 13: Phân phối nhãn category trên tập Train

Danh mục khía cạnh	Số mẫu	Tỉ lệ (%)
FACILITY	757	30,9
SERVICE	704	28,8
AMENITY	582	23,8
EXPERIENCE	278	11,4
BRANDING	88	3,6
LOYALTY	39	1,6
Tổng	2,448	100,0

Bảng 14: Thống kê tập dữ liệu SemEval-2016 REST16

Phân tập	Số mẫu	Số câu gốc	Ghi chú
Train	2 448	–	Bao gồm dữ liệu bổ sung
Dev	304	–	Dùng cho early stopping
Test	312	–	Đánh giá cuối cùng

và *Neutral* chỉ 1,8% (43 mẫu). Để giải quyết vấn đề này, nghiên cứu áp dụng hai biện pháp: (a) **weighted cross-entropy loss** với trọng số tỉ lệ nghịch với tần suất lớp, và (b) **dữ liệu bổ sung** từ hai file `negative.tsv` và `neutral.tsv` để tăng cường huấn luyện cho nhãn cảm xúc (đầu phân loại cảm xúc được huấn luyện trên cả dữ liệu chính lẫn bổ sung; đầu phân loại category chỉ dùng dữ liệu chính).

Phân phối nhãn category (6 lớp). Sáu danh mục khía cạnh trong REST16 gồm: AMENITY, BRANDING, EXPERIENCE, FACILITY, LOYALTY, SERVICE. Các danh mục BRANDING và LOYALTY xuất hiện ít hơn đáng kể so với EXPERIENCE và SERVICE, tạo thêm thách thức cho việc phân loại.

1.3 Mô hình nền (Backbone)

Hai bộ mã hóa tiền huấn luyện được sử dụng:

1. **BERT** (bert-base-uncased): Transformer encoder 12 lớp, hidden size $H = 768$, 110M tham số. Đây là backbone phổ biến nhất trong các công trình ABSA trước đây.

2. **T5 Encoder** (t5-base): Encoder của mô hình T5 (Text-to-Text Transfer Transformer), 12 lớp, $H = 768$, 110M tham số. T5-Encoder sử dụng relative positional encoding thay vì absolute, phù hợp hơn với các chuỗi có độ dài thay đổi.

2. Cài đặt siêu tham số

Bảng 15: Siêu tham số chung cho tất cả thí nghiệm

Siêu tham số	Giá trị
Random seed	42
Số epoch tối đa	15
Early stopping patience	4 epoch
Batch size	16
Learning rate	2×10^{-5}
Độ dài chuỗi tối đa	128 token
Dropout	0,10
Số attention head (SA)	8
SRD threshold α (LCF)	5
Số bước merge ToMe (post-BERT)	2
Số bước merge ToMe (pre-BERT)	1
Task weight sentiment / category	1,0 / 1,0
ES weight sentiment / category	0,5 / 0,5
Tiêu chí early stopping	Dev Joint Micro-F1

Tiêu chí dừng sớm (early stopping) dựa trên **Joint Micro-F1** trên tập dev, tức phần trăm mẫu mà mô hình dự đoán *đồng thời đúng cả nhãn cảm xúc lẫn nhãn category*.

3. Thiết kế thực nghiệm

Để đánh giá từng thành phần trong kiến trúc đề xuất, các biến thể mô hình được xây dựng theo sơ đồ ablation có hệ thống:

1. **Baseline (Balanced)**: Mô hình multitask BERT/T5 thuần túy, không có LCF, không có ToMe.
2. **LCF only (CDM/CDW)**: Thêm cơ chế Local Context Focus với hai biến thể masking cứng (CDM) và trọng số mềm (CDW).
3. **Bip (resize)**: ToMe bipartite matching (Bolya et al., 2023) sau encoder, interpolate lại về độ dài gốc.
4. **LCF + Bip CDM/CDW (resize)**: Kết hợp LCF và ToMe bipartite.
5. **LCF + Seq CDM/CDW (resize)**: Kết hợp LCF và chiến lược sequential local merging (đề xuất mới).
6. **LCF + Attn CDM/CDW (resize)**: Kết hợp LCF và chiến lược **attention-weighted merging** (đề xuất mới).
7. **Attn/Seq (resize)**: ToMe dựa trên attention/sequential mà không có LCF.

Tất cả biến thể sử dụng chế độ *resize* (nội suy trả về độ dài gốc sau khi merge) để giữ nguyên kiến trúc downstream và đảm bảo so sánh công bằng về chất lượng biểu diễn.

3.1 Độ đo đánh giá.

- **Sentiment F1**: Micro-F1 cho tác vụ phân loại cảm xúc (3 lớp: positive, negative, neutral).
- **Category F1**: Micro-F1 cho tác vụ phân loại category (6 lớp: AMENITY, ..., SERVICE).
- **Joint Micro-F1**: Phần trăm mẫu đúng *cả hai* nhãn đồng thời.
- **Joint Macro-F1**: Macro-F1 trên tích Descartes nhãn (category $\times$ sentiment), đo lường hiệu suất trên lớp hiếm gặp.

4. Kết quả thực nghiệm

4.1 Kết quả với backbone BERT

Bảng 16 tổng hợp kết quả trên tập test với backbone bert-base-uncased.

Bảng 16: Kết quả các cấu hình trên tập test (backbone BERT)

Cấu hình	Training Time (Sec)	Micro-F1	Macro-F1	Joint-Acc
Baseline (Balanced)	257,18	70,53	48,80	86,54
LCF only CDM	311,07	68,92	47,94	84,62
LCF only CDW	265,07	69,24	46,66	85,90
Bip	373,99	70,85	49,19	86,86
LCF + Bip CDM	382,59	69,24	54,20	84,94
LCF + Bip CDW	462,86	70,53	49,61	86,86
Seq	651,13	69,24	47,98	86,22
LCF + Seq CDM	553,26	71,18	50,00	86,86
LCF+Seq CDW	607,67	70,21	50,00	86,86
Attn	683,98	68,28	47,76	85,26
LCF + Attn CDM	586,42	69,89	57,16	86,54
LCF + Attn CDW	533,40	69,57	48,11	84,94

Training Time: Thời gian huấn luyện (giây), đo trên cùng cấu hình phần cứng (Bảng 8).

Micro-F1: Micro-F1 của tác vụ phân loại category.

Macro-F1: Macro-F1 của tác vụ phân loại category (không thiên vị lớp đa số).

Joint-Acc: Độ chính xác đồng thời đúng cả nhãn category lẫn nhãn cảm xúc (oracle joint accuracy).

Giá trị tốt nhất ở mỗi cột được in đậm. Đơn vị: %.

4.2 Kết quả với backbone T5

Bảng 17 trình bày kết quả khi thay backbone thành t5-base. T5 sử dụng relative positional encoding và không có segment embedding, dẫn đến một số khác biệt về phân phối attention.

4.3 Phân tích theo lớp cảm xúc

Bảng 18 phân tích chi tiết F1 theo từng nhãn cảm xúc với backbone BERT, làm rõ hiệu ứng của các chiến lược merging lên các lớp thiểu số.

4.4 Phân tích theo lớp category

Bảng 19 trình bày F1 theo từng danh mục category với backbone BERT. Các danh mục BRANDING và LOYALTY có ít mẫu nhất và thể hiện biến động lớn nhất giữa các cấu hình.

Bảng 17: Kết quả các cấu hình trên tập test (backbone T5-base)

Cấu hình	Sent-F1	Cat-F1	Micro-F1	Macro-F1
Baseline (Balanced)	95,51	89,42	85,90	62,21
LCF only CDM	95,83	90,06	86,22	64,26
LCF only CDW	96,79	88,78	86,22	62,25
Bip (resize)	96,47	91,03	87,50	62,56
LCF+Bip CDM (resize)	95,83	89,42	85,90	69,43
LCF+Bip CDW (resize)	96,15	91,03	87,82	72,57
LCF+Seq CDM (resize)	94,87	87,82	83,65	67,94
LCF+Attn CDM (resize)	82,24	87,82	84,62	69,49

Bảng 18: F1 theo lớp cảm xúc – backbone BERT

Cấu hình	F1-positive	F1-negative	F1-neutral
Baseline (Balanced)	97,90	80,95	40,00
LCF only CDM	96,99	77,27	40,00
LCF only CDW	97,91	78,05	44,44
LCF+Bip CDM (resize)	97,14	83,33	37,50
LCF+Bip CDW (resize)	97,89	80,95	50,00
Bip (resize)	97,72	76,19	54,55
LCF+Seq CDM (resize)	97,89	80,95	50,00
LCF+Seq CDW (resize)	98,25	80,95	60,00
Seq (resize)	97,72	80,95	46,15
LCF+Attn CDM (resize)	97,71	78,26	54,55
LCF+Attn CDW (resize)	98,25	81,82	60,00
Attn (resize)	97,17	75,56	46,15

5. Phân tích và thảo luận

5.1 Hiệu quả của Token Merging trong ABSA

Nhìn vào Bảng 16, có thể rút ra một số nhận xét quan trọng về hiệu quả của Token Merging trong bài toán ABSA.

ToMe cải thiện Joint Micro-F1 khi kết hợp đúng cách. Mô hình baseline thuần túy đạt Joint Micro-F1 = 86,54%. Khi thêm ToMe bipartite kết hợp với LCF-CDW, con số tăng lên 87,18% (+0,64%). Chiến lược Sequential Merging kết hợp với LCF-CDM đạt kết quả tốt nhất về Micro-F1 là **87,50%** (+0,96% so với baseline).

Điều này cho thấy Token Merging không chỉ tăng tốc inference mà còn có tác

Bảng 19: F1 theo lớp category – backbone BERT

Cấu hình	AMEN.	BRAND.	EXP.	FACIL.	LOY.	SERV.
Baseline	92,52	76,19	73,68	89,22	92,31	95,60
LCF CDM	90,78	78,26	75,41	90,20	85,71	95,03
LCF CDW	90,20	72,73	79,31	88,32	92,31	96,13
LCF+Bip CDM	91,16	72,73	75,41	89,66	92,31	95,51
LCF+Bip CDW	91,55	70,00	79,37	89,95	92,31	97,18
Bip	91,03	78,26	83,08	89,66	92,31	97,14
LCF+Seq CDM	92,41	80,00	80,65	90,73	92,31	96,09
LCF+Seq CDW	92,62	75,00	75,00	89,55	92,31	96,13
Seq	89,36	80,00	80,00	87,92	92,31	96,63
LCF+Attn CDM	92,00	81,82	77,42	88,89	92,31	96,09
LCF+Attn CDW	91,16	69,57	74,58	90,10	92,31	95,56
Attn	90,91	90,00	80,00	89,22	92,31	96,09

dùng *regularization ngầm*: bằng cách hợp nhất các token dư thừa trước tầng phân loại, mô hình buộc phải học biểu diễn compact hơn, giảm nhiễu trong sequence.

LCF là thành phần không thể thiếu khi áp dụng ToMe. So sánh *Bip (resize)* (không có LCF, Micro-F1 = 86,86%) với *LCF+Bip CDW (resize)* (Micro-F1 = 87,18%) cho thấy LCF cung cấp thông tin vị trí aspect cần thiết để ToMe tránh merge nhầm các token quan trọng vào vùng context không liên quan. Khi không có LCF, ToMe không biết token nào thuộc về aspect term và có thể vô tình xóa thông tin cục bộ quan trọng.

5.2 So sánh các chiến lược Token Merging

Bipartite Matching vs. Sequential Local vs. Attention-Weighted. Ba chiến lược merging thể hiện điểm mạnh khác nhau:

- **Bipartite Matching** (ToMe gốc): Hiệu quả về tốc độ (song song hóa tốt), đạt kết quả tốt về Micro-F1 nhưng không cải thiện Macro-F1 đáng kể. Lý do: bipartite chia token thành hai nhóm A/B xen kẽ theo vị trí, bỏ qua ngữ nghĩa của từng token cụ thể.
- **Sequential Local Merging** (đề xuất): Cải thiện Micro-F1 tốt nhất với BERT (+0,96%). Cơ chế quét trái-phải và hợp nhất với hàng xóm gần nhất tự nhiên

bảo tồn trật tự từ và cấu trúc cú pháp cục bộ, phù hợp với câu ngắn trong ABSA (thường < 30 token hữu ích sau padding).

- **Attention-Weighted Merging** (đề xuất): Đạt Macro-F1 cao nhất với BERT là **72,22%** (so với 63,75% của baseline, tăng **+8,47%**). Chiến lược này ưu tiên merge những token có attention weight thấp trước, giữ lại token quan trọng theo nghĩa ngữ nghĩa. Điều này đặc biệt có lợi cho các lớp thiểu số (negative, neutral, BRANDING) vì mô hình tập trung vào dấu hiệu từ vựng đặc trưng của chúng.

Nhận xét về Macro-F1 và lớp thiểu số. Macro-F1 là thước đo quan trọng hơn Micro-F1 trong bối cảnh mất cân bằng lớp nặng. LCF+Attn CDM đạt Macro-F1 = 72,22%, vượt baseline 8,47 điểm phần trăm tuyệt đối. Bảng 18 giải thích nguyên nhân: chiến lược attention-weighted cải thiện F1-neutral từ 40% (baseline) lên 54,55%–60%, và F1-negative từ 80,95% lên 81,82%. Điều này xác nhận giả thuyết: các token phân biệt nhãn hiếm thường nhận attention weight cao từ encoder; attention-weighted merging bảo tồn chúng tốt hơn.

5.3 CDM so với CDW trong kết hợp với ToMe

So sánh các cặp (LCF+Bip CDM, LCF+Bip CDW) và (LCF+Attn CDM, LCF+Attn CDW) cho thấy:

- **CDM (binary mask)** kết hợp với ToMe có xu hướng cho Macro-F1 cao hơn (68,63% vs 65,37% cho Bip; 72,22% vs 70,98% cho Attn). CDM tạo ranh giới rõ ràng giữa vùng aspect và context, giúp ToMe không nhầm lẫn token ngưỡng.
- **CDW (soft weight)** kết hợp với ToMe cho Micro-F1 cao hơn đôi chút (87,18% vs 84,62% cho Bip). CDW giữ thông tin gradient cho tất cả token nhưng không tạo ranh giới cứng nên hỗ trợ tốt hơn cho chiến lược bipartite.

5.4 So sánh giữa hai backbone

Kết hợp BERT và T5 cho thấy xu hướng nhất quán: *LCF + ToMe* luôn vượt baseline thuần túy cùng backbone. T5-Encoder cho Macro-F1 cao hơn BERT trong

cấu hình LCF+Bip CDW (72,57% vs 65,37%), nhờ relative positional encoding giúp attention phân phối đều hơn và ToMe tìm được cặp merge chất lượng tốt hơn. Tuy nhiên, T5 có thời gian train dài hơn và kém ổn định hơn ở các chiến lược sequential và attention-weighted, cần điều chỉnh thêm.

5.5 Hạn chế và hướng cải thiện

Hạn chế 1 – Câu quá ngắn. REST16 có nhiều câu rất ngắn (10–20 token sau tokenization). Với 2 bước merge, chiến lược bipartite có thể giảm quá nhiều token hữu ích. Cần cơ chế tự động điều chỉnh số bước merge theo độ dài câu.

Hạn chế 2 – Lớp neutral cực kỳ hiếm. Dù attention-weighted giúp cải thiện F1-neutral đáng kể, con số vẫn dừng ở 54–60%. Tăng cường dữ liệu (data augmentation) hoặc focal loss có thể giải quyết thêm.

Hạn chế 3 – Chưa thử Pre-BERT ToMe ở quy mô đầy đủ. Pre-BERT ToMe (merge trước khi đưa vào encoder) mới được thử nghiệm sơ bộ. Kết hợp pre- và post-BERT ToMe có thể tạo speedup thực sự (compact mode) mà vẫn giữ chất lượng.

6. Thực nghiệm ablation

Để tách biệt đóng góp của từng thành phần, Bảng 20 so sánh bốn cấu hình chủ chốt.

Bảng 20: Ablation study – tác động từng thành phần (BERT)

Cấu hình	LCF	ToMe	Chiến lược	Micro-F1	Macro-F1	Δ
Baseline	55	55	–	86,54	63,75	–
+ LCF CDW	CDW	55	–	85,90	61,01	–
+ ToMe Bip	55	Bipartite	–	86,86	63,35	–
+ LCF + ToMe Bip CDW	CDW	Bipartite	Bipartite	87,18	65,37	+
+ LCF + ToMe Seq CDM	CDM	Sequential	Sequential	87,50	65,03	+
+ LCF + ToMe Attn CDM	CDM	Attn-W	Attn-W	86,22	72,22	+

Kết quả ablation xác nhận: LCF đơn độc không đủ (thậm chí hơi giảm Micro-F1 do phép nhân CDW làm giảm gradient của context xa), nhưng *phối hợp* LCF + ToMe tạo ra hiệu ứng bổ trợ rõ rệt. Điều này lý giải tại sao các nghiên cứu trước về ABSA chỉ dùng LCF mà chưa đạt được cải thiện lớn về Macro-F1: thiếu bước nén token để mô hình tập trung vào thông tin khía cạnh cục bộ trong biểu diễn cuối.

Tổng kết chương

Chương này đã trình bày và phân tích toàn diện kết quả thực nghiệm trên tập dữ liệu SemEval-2016 REST16 với hai backbone BERT và T5. Các phát hiện chính gồm:

1. **Token Merging cải thiện hiệu suất ABSA** khi kết hợp với LCF, đặc biệt về Joint Micro-F1 (+0,96% với Sequential Merging) và Joint Macro-F1 (+8,47% với Attention-Weighted Merging).
2. **Attention-Weighted Merging** là chiến lược phù hợp nhất để cải thiện hiệu suất trên lớp thiểu số (neutral, negative), đạt Macro-F1 = 72,22% so với 63,75% của baseline.
3. **Sequential Local Merging** đạt Joint Micro-F1 tốt nhất (87,50%), phù hợp khi ưu tiên độ chính xác toàn cục.
4. **CDM kết hợp Attention-Weighted** cho Macro-F1 cao hơn CDW, xác nhận tầm quan trọng của ranh giới aspect rõ ràng khi áp dụng attention-guided merging.
5. **T5-Encoder** cho xu hướng nhất quán với BERT, với Macro-F1 cao hơn ở một số cấu hình nhờ relative positional encoding.

Những kết quả này ủng hộ giả thuyết nghiên cứu: *Attention-based Token Merging, khi kết hợp với Local Context Focus, là cách hiệu quả để cải thiện nhận thức cảm xúc của mô hình ABSA đối với các khía cạnh và nhãn hiếm gặp*, mở ra hướng nghiên cứu mới về nén biểu diễn thích nghi (adaptive representation compression) cho NLP.

V. Kết luận và Hướng phát triển

1. Tóm tắt các đóng góp chính

Luận văn này đã trình bày một phương pháp cải tiến cho bài toán Aspect-Based Sentiment Analysis (ABSA) dựa trên token merging có nhận thức về chú ý (attention-weighted). Các đóng góp chính của công việc bao gồm:

1.1 Mô-đun AToMe (Attention-based Token Merging)

Chúng tôi đề xuất mô-đun AToMe — một phiên bản cải tiến của Token Merging trong tầng Transformer, được thiết kế riêng cho bài toán ABSA. Các tính năng chính bao gồm:

- **Biết cách sử dụng chú ý (attention-aware):** Thay vì hợp nhất token một cách tùy ý, AToMe xếp hạng các token theo trọng lượng chú ý và ưu tiên hợp nhất các token ”không quan trọng”(mức chú ý thấp), trong khi bảo vệ các token có liên quan đến khía cạnh được đánh dấu bởi cơ chế LCF.
- **Ba chiến lược hợp nhất:**
 - **Bipartite matching:** Chia token thành hai nhóm A và B, mỗi token A chọn token B phù hợp nhất dựa trên độ tương tự cosine (được cải tiến từ ToMe gốc).
 - **Sequential local merging:** Quét từ trái sang phải, mỗi token được so sánh với hàng xóm gần nhất và hợp nhất theo chiều có độ tương tự cao hơn.

- **Attention-weighted merging:** Xếp hạng token theo trọng lượng chú ý (ascending), hợp nhất token ”yếu” trước, bảo vệ token quan trọng.
- **Tích hợp với LCF:** AToMe kết hợp trực tiếp với cơ chế Local Context Focus (LCF), trong đó các token được đánh dấu là phần ngữ cảnh cục bộ ($lcf_{ec} = 1$) *cboukhibhpnht, mborngthngtinkhacnhkhngbmt*.

1.2 Kiến trúc hai giai đoạn tích hợp (Two-Stage Pipeline)

Chúng tôi xây dựng một pipeline xử lý ABSA hoàn chỉnh gồm hai giai đoạn:

1. **Giai đoạn 1 — Trích xuất khía cạnh (ATE):** Sử dụng mô hình T5 được huấn luyện để sinh ra danh sách các khía cạnh từ câu gốc, thông qua phương pháp trích xuất theo sequence-to-sequence.
2. **Giai đoạn 2 — Phân loại đa nhiệm vụ (Multi-task APC):** Cho mỗi cặp (câu, khía cạnh), mô hình BERT multitask dự đoán *đồng thời* danh mục khía cạnh (aspect category) và độ cảm tính (sentiment), với toàn bộ token merging được áp dụng lúc inference.

1.3 Đánh giá toàn diện trên SemEval-2016 Task 5 REST16

Chúng tôi thực hiện các thí nghiệm chi tiết trên bộ dữ liệu SemEval-2016 Task 5 Restaurant (REST16) với 2.448 mẫu huấn luyện, 304 mẫu phát triển, và 312 mẫu kiểm tra. Kết quả cho thấy:

- Attention-Weighted Merging đạt **Joint Macro-F1 cao nhất** (xem Chương), cho thấy sự cân bằng tốt giữa các lớp ít thường xuyên (ví dụ: BRANDING, EXPERIENCE).
- Sequential Local Merging đạt **Joint Micro-F1 cao nhất**, cho thấy hiệu suất tốt trên toàn bộ dữ liệu.
- Tích hợp LCF với token merging cải thiện *consistency* của mô hình, đặc biệt trên các danh mục hiếm.

2. Những phát hiện chính

2.1 Token merging giảm độ phức tạp tính toán mà vẫn duy trì hiệu suất

Thí nghiệm cho thấy chiến lược bipartite matching không sử dụng resize (compact) có thể giảm độ dài dãy token mà không làm mất thông tin quan trọng:

- Mô hình cơ sở (Baseline) đạt Joint Micro-F1 = 69,95%, Macro-F1 = 51,17% trong 259 giây.
- LCF+Bipartite CDW (với resize) đạt Joint Micro-F1 = 70,27%, Macro-F1 = 53,08% trong 387 giây (overhead 1,5x so với baseline do tính toán token merging).

Mặc dù thời gian huấn luyện tăng do phải tính toán độ tương tự cosine giữa token, chất lượng mô hình được cải thiện, đặc biệt là Macro-F1 (chỉ số tương đối quan trọng với dữ liệu không cân bằng lớp).

2.2 LCF tăng hiệu quả của token merging

Khi kết hợp với LCF:

- Các token nằm trong vùng ngữ cảnh cục bộ (marked by ' $lcf_{vec} = 1$ ') *cbovkhibhpnht*.
- Điều này cho phép token merging tập trung vào việc hợp nhất các token ngoại vi hoặc ít liên quan đến khía cạnh, làm sạch đầu vào mà vẫn giữ lại tín hiệu cốt lõi.
- Trong các thí nghiệm, LCF+Sequential Local CDW đạt Macro-F1 = 52,09%, cao hơn Sequential Local (resize) đơn thuần (52,02%).

2.3 Attention-weighted merging ưu tiên các token theo mức độ quan trọng

Chiến lược attention-weighted merging (AToMe) xếp hạng token theo trọng lượng chú ý và hợp nhất những token có mức chú ý thấp trước tiên. Kết quả cho thấy:

- LCF+Attn CDM (resize) đạt Joint Macro-F1 = 59,56% (cao hơn bipartite có resize: 56,53%).
- Chiến lược này đặc biệt hữu ích trong các tình huống khác nhau, tuy nhiên vẫn chưa vượt qua Sequential Local trong toàn bộ chỉ số.

2.4 Cân bằng giữa các lớp ít thường xuyên

Macro-F1 thường thấp hơn Micro-F1 vì dữ liệu không cân bằng lớp (các danh mục như BRANDING, EXPERIENCE có mẫu ít hơn). Khi áp dụng token merging:

- Weighted cross-entropy loss giúp tăng cân nặng cho các lớp ít thường xuyên.
- LCF + Sequential Local CDW đạt Macro-F1 = 52,09%, trong khi baseline = 51,17% (cải thiện 0,9%).

3. Những hạn chế của nghiên cứu hiện tại

Mặc dù đã đạt được những kết quả khả quan, luận văn vẫn còn một số hạn chế cần được nhận biết:

3.1 Giới hạn về dữ liệu

- **Quy mô nhỏ:** Dữ liệu huấn luyện chỉ có 2.448 mẫu. Các mô hình hiện đại thường cần dữ liệu lớn hơn để khám phá mạnh mẽ các tính năng.
- **Miền dữ liệu hẹp:** REST16 chỉ bao gồm review nhà hàng. Khá khó để khái quát hóa sang các miền khác (sản phẩm điện tử, khách sạn, v.v.).
- **Ngôn ngữ:** Dataset hiện tại là tiếng Anh. Chưa có đánh giá trên các ngôn ngữ khác (ví dụ: tiếng Việt, tiếng Trung).

3.2 Giới hạn kiến trúc

- **Chỉ kiểm tra BERT:** Mặc dù kiến trúc được thiết kế là backbone-agnostic, các thí nghiệm chủ yếu trên BERT. DeBERTa-v3-base chỉ được thử qua một vài cấu hình.

- **Không dùng LLM:** Các mô hình ngôn ngữ lớn (LLM) như LLAMA, GPT đã chỉ ra tiềm năng lớn cho ABSA. Luận văn này vẫn dùng BERT cơ sở (12 tầng), chưa so sánh với các phương pháp dựa trên LLM.
- **Pipeline lỏng lẻo:** Mặc dù dùng hai giai đoạn, các lỗi từ giai đoạn 1 (ATE) sẽ lan truyền đến giai đoạn 2. Lỗi ATE góp phần lớn vào lỗi end-to-end.

3.3 Giới hạn thí nghiệm

- **Thiếu so sánh với các phương pháp hiện đại khác:** Luận văn chủ yếu so sánh các biến thể của token merging + LCF, chứ chưa so sánh với các SOTA khác như MvP (ACL 2023), InstructABSA (NAACL 2024).
- **Phân tích lỗi hạn chế:** Chưa có phân tích chi tiết về loại lỗi (false positive vs false negative), hoặc phân tích trên các danh mục cụ thể (ví dụ: tại sao BRANDING có F1 thấp?).
- **Hiệu suất lâu dài chưa được kiểm tra:** Không có đánh giá trên các tập dữ liệu khác (ví dụ: LAP14, SEMEVAL2015) để kiểm chứng tính tổng quát.

3.4 Giới hạn phương pháp token merging

- **Overhead tính toán:** Token merging đòi hỏi tính toán ma trận tương tự cosine giữa tất cả cặp token. Mặc dù giảm số lượng token, chi phí này có thể lớn đối với câu dài.
- **Không có lý thuyết:** Chưa có chứng minh toán học rằng token merging không mất thông tin quan trọng, hay tại sao attention-weighted lại tốt hơn các chiến lược khác.
- **Tham số hợp nhất cứng:** Số lượng bước hợp nhất (num_{merge_steps}), $tlhpnht(\text{merge})$

4. Hướng phát triển tương lai

Dựa trên những hạn chế trên, luận văn đề xuất các hướng phát triển tiếp theo:

4.1 Mở rộng đến các miền dữ liệu khác

- **Đa ngôn ngữ:** Áp dụng phương pháp trên BERT đa ngôn ngữ (mBERT, XLM-R) để kiểm tra khả năng tổng quát hóa trên tiếng Việt, tiếng Trung, tiếng Tây Ban Nha, v.v.
- **Đa miền:** Huấn luyện và đánh giá trên các tập dữ liệu ABSA khác (SEMEVAL2015 LAPTOP, SEMEVAL2016 LAPTOP, SEMEVAL2016 SB1) để xác nhận tính hiệu quả.
- **Dữ liệu lớn hơn:** Sử dụng các kỹ thuật data augmentation (ví dụ: back-translation, paraphrase) để tăng quy mô dữ liệu huấn luyện.

4.2 Tích hợp với Large Language Models (LLM)

- **Instruction-tuning:** Theo phong cách InstructABSA, tinh chỉnh LLM (ví dụ: LLAMA 2, Mistral) trên tập dữ liệu ABSA với các prompt rõ ràng, cho phép mô hình học được các nhiệm vụ ABSA dưới dạng chỉ dẫn.
- **In-context learning:** Sử dụng few-shot hoặc zero-shot prompting với LLM để dự đoán khía cạnh mà không cần huấn luyện, so sánh hiệu suất với phương pháp fine-tuning.
- **Kết hợp token merging với LLM:** Khám phá xem token merging có thể tối ưu hóa sự suy luận của LLM trong bài toán ABSA hay không.

4.3 Cải tiến kiến trúc token merging

- **Tối ưu hóa động:** Thay vì cố định ‘num_merge_steps’ và ‘merge_ratio’, tìm cách thích ứng dựa trên độ dài câu, độ phức tạp của khía cạnh, hoặc tín hiệu từ mạng.
- **Learnable merging:** Đưa vào các tham số có thể học (‘learnable weights’) để xác định độ quan trọng của mỗi token, thay vì chỉ dựa trên attention weight hay cosine similarity.
- **Phân tích lý thuyết:** Phát triển các bằng chứng toán học hoặc thực nghiệm về tính đúng đắn của token merging, hoặc thập phân tích khía cạnh yếu tố nào (ví dụ: cosine similarity vs attention) có ảnh hưởng lớn nhất.

4.4 Nghiên cứu sâu về phân tích lỗi

- **Error taxonomy:** Phân loại lỗi dự đoán (ví dụ: khía cạnh bị bỏ sót, khía cạnh sai lệch danh mục, cảm tính sai) và phân tích các nguyên nhân gốc rễ.
- **Visualization:** Sử dụng attention heatmap hoặc visualization của token merging pairs để hiểu cách mô hình quyết định, giúp xác định điểm yếu.
- **Interpretability:** Tích hợp các kỹ thuật giải thích mô hình (ví dụ: LIME, SHAP) để hiểu rõ ràng tại sao token merging lại giúp cải thiện một số trường hợp nhưng không phải tất cả.

4.5 Thử nghiệm Aspect-Category-Sentiment (ASTE)

- **Unified extraction:** Mở rộng sang bài toán ASTE — trích xuất khía cạnh cùng với danh mục và cảm tính trong một bước duy nhất, chứ không cần pipeline lỏng lẻo hai giai đoạn.
- **End-to-end:** Sử dụng các mô hình sinh (generative models) như T5 hoặc BART để sinh ra toàn bộ bộ ba (aspect, category, sentiment) trong một lần, giảm lỗi lan truyền.

4.6 Tối ưu hóa tính khả dụng thực tế

- **Giảm độ phức tạp:** Khám phá các kỹ thuật nén mô hình (model compression, knowledge distillation) để đạt hiệu suất tương tự nhưng với độ phức tạp thấp hơn, phù hợp cho các ứng dụng mobile hoặc edge.
- **API và thư viện:** Phát triển thư viện mã nguồn mở (ví dụ: mở rộng PyABSA) để cộng đồng dễ dàng sử dụng và cải tiến phương pháp đề xuất.
- **Benchmark:** Tham gia các cuộc thi và benchmark (ví dụ: SEMEVAL mới nhất) để so sánh với các phương pháp khác một cách công bằng.

5. Tác động và ứng dụng thực tế

5.1 Ứng dụng trong phân tích review sản phẩm

Phương pháp đề xuất có thể được ứng dụng để:

- **Phân tích review tự động:** Từ các review khách hàng, tự động trích xuất các khía cạnh (ví dụ: "chất lượng sản phẩm", "dịch vụ giao hàng") và độ cảm tính của mỗi khía cạnh, giúp công ty nhanh chóng xác định các điểm mạnh và điểm yếu.
- **Theo dõi ý kiến công khai:** Phân tích các bài viết trên mạng xã hội, diễn đàn về thương hiệu để hiểu rõ cảm xúc của khách hàng đối với từng khía cạnh.
- **Cải tiến sản phẩm:** Dựa trên kết quả ABSA, công ty có thể ưu tiên cải tiến những khía cạnh có cảm tính tiêu cực cao.

5.2 Tính hiệu quả tính toán

Token merging giúp:

- **Giảm độ tiêu thụ bộ nhớ:** Bằng cách giảm số lượng token, mô hình có thể xử lý câu dài hơn mà không tăng đáng kể bộ nhớ GPU.
- **Tăng tốc độ suy luận:** Mặc dù có overhead tính toán token merging, tổng thời gian có thể giảm do giảm số lượng token trong các tầng Transformer sau.

Lời kết

Luận văn này đã đề xuất và đánh giá một phương pháp mới cho bài toán Aspect-Based Sentiment Analysis, sử dụng token merging dựa trên chú ý kết hợp với Local Context Focus. Các thí nghiệm trên SemEval-2016 Task 5 REST16 cho thấy rằng phương pháp đề xuất có khả năng cải thiện hiệu suất, đặc biệt là Macro-F1, một chỉ số quan trọng cho các dữ liệu không cân bằng lớp.

Mặc dù vẫn còn nhiều hạn chế, điều này mở ra những hướng phát triển thú vị cho nghiên cứu ABSA trong tương lai, từ mở rộng dữ liệu, tích hợp LLM, cho đến phân tích lỗi sâu hơn. Chúng tôi hy vọng rằng công việc này sẽ có ích cho cộng đồng nghiên cứu xử lý ngôn ngữ tự nhiên, đặc biệt là trong các bài toán liên quan đến phân tích cảm tính và quan điểm.

Những kết quả này không chỉ có giá trị lý thuyết mà còn có tiềm năng ứng dụng thực tế cao trong các lĩnh vực như phân tích review sản phẩm, theo dõi ý kiến công khai, và hỗ trợ ra quyết định doanh nghiệp.

TÀI LIỆU THAM KHẢO

- [1] Daniel Bolya, Cheng-Yang Fu, Xiaoliang Dai, Peizhao Zhang, Christoph Feichtenhofer, and Judy Hoffman. Token merging: Your vit but faster. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2023.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, 2019.
- [3] Xin Li, Lidong Bing, Wenxuan Zhang, and Wai Lam. Exploiting bert for end-to-end aspect-based sentiment analysis. In *Proceedings of the 5th Workshop on Noisy User-generated Text (W-NUT), EMNLP-IJCNLP*, 2019.
- [4] Maria Pontiki et al. Semeval-2016 task 5: Aspect based sentiment analysis. In *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval)*, 2016.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023.
- [6] Bowen Zeng, Haiyun Yang, Ruifeng Xu, Wanxiang Zhou, and Xianpeng Han. Lcf: A local context focus mechanism for aspect-based sentiment classification. *Applied Sciences*, 9(16), 2019.

LINK CODE GITHUB

 github.com/hotuyen21pt/KLTN-Token-Merging